

同濟大學

TONGJI UNIVERSITY

《数据采集与集成技术》

实验报告

实验名称

数据集成

实验成员

( )

日期

2025 年 12 月 15 日

## 1、实验目的

本次实验旨在通过以某大型混凝土生产企业的实际业务数据（原材料配比、养护时间、强度测试）为具体对象，引导学习者深入掌握多源数据集成与可视化分析的全流程。核心目标在于深刻理解并能实际操作数据清洗、模式对齐、记录连接与数据融合等关键技术环节。实验要求我不仅要熟练运用 Python 的 Pandas 库来完成 Excel 文件的读取、缺失值处理及数据列重命名（如统一关联键），还要掌握使用 merge 等操作将分散在不同数据源中的实体信息（element.xlsx、age.xlsx、strength.xlsx）进行逻辑关联与整合。此外，实验强调了数据特征挖掘与可视化展示的能力，要求能够利用 Matplotlib 和 Seaborn 库绘制散点图、柱状图及相关性热力图，直观揭示水泥含量、养护龄期与抗压强度之间的潜在关系。最终，实验旨在打通从多源数据读取、预处理集成、整合存储到可视化洞察的完整链路，从而将理论知识与实践应用相结合，全面提升应对复杂工程数据处理与分析项目的综合能力。

## 2、实验内容

本实验围绕多源异构数据的全生命周期处理展开，从基础的文件读取与属性对齐入手，逐步过渡到复杂的数据逻辑关联与融合。在此基础上，实验进一步要求对清洗后的数据进行持久化存储，并通过多维度的图形化展示来挖掘数据特征。通过这一过程，旨在巩固对 Pandas 数据处理库的掌握，并建立从原始数据到可视化决策支持的完整分析链路。

具体实验内容划分如下：

### 2.1 基础数据读取与模式对齐

该任务是数据集成的准备阶段。我利用 Pandas 库分别读取某大型混凝土生产企业提供的三个独立 Excel 文件：原材料配比信息（element.xlsx）、养护时间数据（age.xlsx）及强度测试结果（strength.xlsx）。在此过程中，重点在于识别不同数据表中表示同一实体的异构属性名（例如“No.”与“number”）。我通过编写程序，使用 rename 函数统一这些关联键的命名，从而完成模式对齐，为后续的数据融合扫清结构性障碍。

### 2.2 多源数据融合与清洗

本任务是实验的核心环节，我利用 pd.merge 函数，基于前一步统一的“number”键，将分散的原材料、养护期和强度数据精确地关联到同一个混凝土实体上，实现记录连接（Record Linkage）。

在融合过程中，必须建立数据质量意识，检查合并后的宽表是否存在缺失值，并使用 dropna 等方法进行清洗处理。最终，将处理干净、逻辑完整的集成数据集保存为新的文件，实现数据的持久化，供后续分析使用。。

### 2.3 统计分析与可视化展示

任务旨在通过图形化手段揭示数据背后的物理规律。我利用 Matplotlib 和 Seaborn 库对集成后的数据进行深度探索：

- **趋势分析：**绘制“水泥含量 vs 抗压强度”的散点图，观察核心原料对产品性能的分布影响；
- **聚合分析：**使用 groupby 对数据分组，绘制“不同龄期（Age）平均抗压强度”的柱状图，展示时间维度上的强度增长趋势；
- **相关性挖掘：**计算所有数值属性的相关性矩阵，并绘制热力图（Heatmap），直观呈现水、矿渣、粉煤灰等各要素之间的正负相关程度，完成特征挖掘。

### 3、实验步骤

#### 3.1 数据导入

在开始数据集成实验前，首先需要准备好实验环境。这个实验依赖于几个核心的 Python 库，我们在代码的开头将它们全部导入。pandas 是用于数据读取、处理和分析的核心库，它提供了 DataFrame 这一强大的数据结构，能够像操作 Excel 表格一样灵活地处理数据。matplotlib.pyplot 是用于绘制基础图表的库，它是 Python 中最常用的可视化工具，提供了丰富的绘图函数。seaborn 则是基于 matplotlib 的高级统计可视化库，它能够以更少的代码创建更美观、更具信息量的统计图表。

在导入库之后，我们需要从三个独立的 Excel 文件中读取数据。这三个文件是本次数据集成实验的原始数据源，它们分别存储了混凝土数据的不同方面。element.xlsx 文件包含了混凝土的原材料配比信息，记录了水泥、矿渣、粉煤灰、水、减水剂、粗骨料和细骨料等七种成分的具体用量，每一行代表一个混凝土样本的配合比设计。age.xlsx 文件记录了每个混凝土样本的养护时间数据，即从浇筑到测试经过的天数，这个龄期参数对混凝土强度有着显著影响。strength.xlsx 文件则包含了最终的强度测试结果，记录了每个样本的抗压强度值，这是评价混凝土性能的核心指标。

#### 3.2 模式对齐 (Schema Alignment)

模式对齐是数据集成的第一步，目标是统一来自不同数据源的属性命名。通过分析发现，age.xlsx 文件中使用“No.”作为编号列名，而 element.xlsx 使用“number”。为了后续的数据融合，需要将这些表示相同含义但命名不同的列进行重命名。在确认了需要重命名的列后，我使用 pandas 的 rename() 方法进行模式对齐。这一步骤是记录连接的前提，确保不同表之间有统一的连接键。最后，age.xlsx 中的“No.”和 strength.xlsx 中的“serial\_number”均已成功修改为“number”。

通过对比发现，有 150 个 (801-651) 样本虽然拥有原材料配比和养护时间数据，但缺失最终的强度测试结果。在后续进行“记录连接”操作时，如果采用内连接 (Inner Join) 策略，最终集成的有效数据集大小将受限于最小的数据集，预计最终将生成 651 条完整记录，其余 150 条无标签数据将被自动过滤。

#### 3.3 记录连接 (Record Linkage)

##### 3.3.1 基于编号进行第一次数据合并

记录连接是数据集成的核心步骤，基于实体标识符 (这里是混凝土样本编号 number) 判断不同数据源中的记录是否为同一实体。例如，element.xlsx 中编号为 180000 的记录和 age.xlsx 中编号为 180000 的记录，虽然来自不同文件，但它们描述的是同一个混凝土样本的不同属性。

我首先将 element\_df 和 age\_df 进行合并。使用 inner join 策略，确保只保留在两个表中都存在的记录，这种策略可以自动过滤掉不匹配的数据。合并结果 (801, 9)，数据集的属性列由原来的 8 列 (Element 表) 扩展至 9 列。通过此次连接，数据实体不仅具备了“物质组成”特征 (水泥、矿渣等 7 种成分)，还增加了“时间维度”特征 (Age)。这为后续分析“在特定配比下，经过特定时间养护后的性能变化”奠定了基础结构。

##### 3.3.2 合并强度测试数据

在完成第一次合并后，我继续将 strength\_df 合并到已有的数据中。这一步同样使用 number 作为连接键，通过 inner join 确保数据的完整性。由于 strength.xlsx 仅包含 651 个样本的测试结果，在执行内连接 (Inner Join) 时，系统自动过滤掉了那 150 个仅有原材料配比和养护时间但缺乏最终强度测试结果的“未标记样本”。这一步骤确保了最终数据集中的每一行都是完整的 (Complete Case)，既包含输入特征 (X)，也包含目标变量 (Y)，完全符合后续监督学习或相关性分析对数

据质量的要求。

最终数据集包含 10 个属性列，分别是标识符 1 列，输入特征 8 列——7 种原材料成分（水泥、矿渣、粉煤灰、水、减水剂、粗/细骨料）和 1 个时间维度（Age），目标变量 1 列：Concrete compressive strength（抗压强度）。

通过三次数据流的汇聚，成功构建了一张标准的宽表（Wide Table），实现了从分散的原始记录到高价值分析数据的转化。

### 3.4 数据融合与质量检查（Data Fusion）

数据融合阶段需要判断是否存在数据冲突和缺失问题。我首先检查合并后数据中的缺失值情况，这对于评估数据质量至关重要。检查后发现所有列均无缺失值。

除了缺失值，还需要检查是否存在重复的记录。这种情况可能在数据采集或录入过程中产生，需要及时发现并处理。检查后发现所有列不重复。

在确认数据质量问题后，执行必要的清洗操作。虽然在本实验中数据质量较好，但我仍然保留清洗代码以确保流程的完整性。

为了提高数据的可读性，我们将列按照逻辑顺序重新排列：先是标识信息（编号），然后是原材料配比信息，接着是养护时间，最后是强度测试结果。经过清洗和列序调整后，最终生成的数据集具有清晰的逻辑结构。对调整后的数据形态分析如下：

- 符合物理因果的逻辑排序

排序策略：列顺序被调整为“样本编号→原材料成分→养护时间→强度结果”。

这种排列方式不再是随意的（基于合并顺序），而是严格遵循了混凝土生产的物理流程：先确定配方（Input），再经历养护过程（Process），最后测量性能（Output）。这种结构极大地提升了数据的可读性，便于人工核查和理解数据背后的业务含义。

- 分析建模的就绪状态

输入与输出分离：

特征变量 X：第 2 至第 9 列（水泥到养护龄期）构成了完整的特征矩阵。

目标变量 Y：最后一列（抗压强度）明确作为预测目标。

当前的数据结构已经完全符合机器学习或统计分析的标准格式。后续进行相关性分析（如计算相关矩阵）或回归预测时，可以轻松地通过切片操作分离特征与标签。

- 微观样本校验

以第一条记录（编号 180000）为例：该样本显示水泥含量高达 540.0 kg/m<sup>3</sup>，矿渣 0、粉煤灰 0、水 162 kg/m<sup>3</sup>、减水剂 2.5 kg/m<sup>3</sup>、粗骨料 1040 kg/m<sup>3</sup>、细骨料 676 kg/m<sup>3</sup>，在 28 天标准养护后，达到了 79.99 MPa 的极高强度。这符合材料学常识（极低的水胶比通常预示着极高的强度），进一步验证了数据集成过程中没有发生错位现象，数据真实可靠，可进入下一步的可视化环节。

完成所有数据集成和清洗工作后，我将最终结果保存为新的 Excel 文件，以便后续分析使用。

## 4、实验结果

### 4.1 描述性统计信息

在完成可视化分析后，我们需要生成量化的统计摘要来补充图形分析。描述性统计提供了数据的数值概要，包括集中趋势、离散程度和分布形态的各种指标。

表 1 集成后混凝土数据集统计表

| 统计指标  | 水泥     | 矿渣     | 粉煤灰    | 水      | 减水剂   | 粗骨料     | 细骨料    | 龄期     | 抗压强度  |
|-------|--------|--------|--------|--------|-------|---------|--------|--------|-------|
| Count | 651    | 651    | 651    | 651    | 651   | 651     | 651    | 651    | 651   |
| Mean  | 280.38 | 75.97  | 53.27  | 180.45 | 6.31  | 972.64  | 777.22 | 46.27  | 36.36 |
| Std   | 102.89 | 86.94  | 63.33  | 21.28  | 6.02  | 75.85   | 80.05  | 64.36  | 16.85 |
| Min   | 102.00 | 0.00   | 0.00   | 121.80 | 0.00  | 801.00  | 594.00 | 1.00   | 2.33  |
| 25%   | 193.35 | 0.00   | 0.00   | 164.40 | 0.00  | 932.00  | 744.15 | 7.00   | 23.83 |
| 50%   | 275.10 | 24.00  | 0.00   | 183.20 | 6.60  | 968.00  | 780.70 | 28.00  | 35.17 |
| 75%   | 350.00 | 144.85 | 118.30 | 192.00 | 10.40 | 1028.40 | 825.50 | 56.00  | 46.52 |
| Max   | 540.00 | 359.40 | 200.00 | 246.90 | 32.20 | 1145.00 | 992.60 | 365.00 | 82.60 |

#### 4.2 散点图：水泥含量与抗压强度关系

该散点图直观展示了混凝土样本中水泥含量现象表明，水泥含量并非决定强度的唯一变量。本实验中集成的其他特征——如水胶比 ( $\text{kg/m}^3$ )、养护龄期 (Age)、以及矿物掺合料（矿渣、粉煤灰）的配分布特征。

从图 1 中可以看出，二者总体呈现出一定的正相关趋势，即随着水泥用量的增加，对最终强度起着至关重要的调节作用。这也侧面说明了进行多源数据集成和多维特征分析的必要性。




图 1 水泥含量与抗压强度关系散点图

#### 4.3 柱状图：不同龄期的平均抗压强度

为了分析养护时间对混凝土强度的影响，我们按龄期对数据进行分组统计，计算每个龄期的平均抗压强度，然后用柱状图展示结果。使用 `groupby` 方法可以高效地完成数据聚合操作。




图2 不同龄期的平均抗压强度柱形图

#### 4.4 热力图：属性相关性分析

相关性热力图能够展示所有数值属性之间的相关关系。我使用 seaborn 的 heatmap 函数创建一个色彩丰富的矩阵图，其中颜色深浅表示相关性强弱。首先需要为列重命名以便在图表中更好地显示。




图3 属性相关性分析热力图

#### 4.5 直方图：各成分含量分布

该图组展示了数据集中 7 种原材料成分（输入变量）及 1 种抗压强度（输出变量）的频率分布情况。图中蓝色直方图代表数据频数，红色虚线表示均值（Mean），绿色虚线表示中位数（Median）。通过观察各子图，可以得出以下分析结论：

### ● 辅助材料的“零膨胀”与右偏分布

矿渣（Slag）、粉煤灰（Fly Ash）及减水剂（Superplasticizer）的分布呈现出显著的右偏（Right-skewed）特征。特别是粉煤灰和减水剂，其频数最高的区间均位于 0 值附近（粉煤灰的中位数甚至为 0.0）。这在业务上解释为：数据集中包含了大量未参加矿物掺合料或外加剂的普通混凝土样本，这些成分属于“可选添加项”。

### ● 核心材料的近似正态分布

水（Water）、粗骨料（Coarse Aggregate）和细骨料（Fine Aggregate）的分布形态较为对称，呈现出近似正态分布（Normal Distribution）的特征。它们的均值与中位数高度重合（例如水的均值 180.4 与中位数 183.2 非常接近），说明这些基础成分在大多数配比设计中保持在相对稳定的工艺范围内。

### ● 水泥含量的多态性

水泥（Cement）的分布范围极广（100~550 kg/m<sup>3</sup>），且没有明显的单一峰值。这反映了实验数据涵盖了从低标号（低水泥用量）到高标号（高水泥用量）的多种强度等级混凝土，数据覆盖面较全。

### ● 目标变量（抗压强度）的分布特征

抗压强度（Strength）的分布大体呈正态分布，主要集中在 20~60 MPa 区间，均值约为 36.4 MPa。分布的长尾效应较弱，说明极低强度或超高强度的离群点较少，样本整体质量较为均匀，适合进行回归模型的训练与预测。

通过分布分析可见，数据集具有良好的多样性。既包含了基础成分稳定的常规样本，也包含了成分差异巨大的特殊配比样本（如掺入大量矿渣或粉煤灰），这为后续挖掘不同成分对强度的复杂非线性影响提供了坚实的数据基础。

混凝土各成分含量分布图




图 4 混凝土各成分含量分布图

## 4.6 小提琴图：成分分布特征分析

小提琴图结合了箱线图与核密度图的特点，能够同时展示数据的统计概括（中位数、四分位数）和概率密度分布形状。分析结论得到以下结果：

①**骨料的主导地位**：观察右侧的粗骨料和细骨料，其“小提琴”形状宽大且位置较高，表明

它们构成了混凝土体积的主体，且分布相对接近正态分布，说明生产控制较为稳定。

②**辅助胶凝材料的“零膨胀”现象**：矿渣和粉煤灰的图形底部极其宽大（呈倒钉子状），中位数线贴近 0 值。这揭示了数据集中存在大量未掺加这两种矿物掺合料的样本（即值为 0）。

③**用水量的严格控制**：水的分布图形呈扁平且对称的梭形，主要集中在  $150\text{--}220\text{ kg/m}^3$ 。这反映了在混凝土配合比设计中，水胶比受到严格限制，因此用水量的波动范围较小。




图 5 混凝土各成分分布小提琴图

## 4.7 箱线图：强度随龄期演变规律

该图展示了在不同养护龄期（X 轴）下，混凝土抗压强度（Y 轴）的分布情况。箱体内的红线/橙色菱形代表均值/中位数，箱体高度代表数据的离散程度。从第 1 天到第 28 天，抗压强度的增长极为显著，呈现出陡峭的上升趋势；而超过 28 天（如 56 天、90 天）后，强度增长速率明显放缓并趋于平稳。这完美验证了混凝土强度的对数增长规律。




图 6 混凝土强度随龄期演变规律箱线图

## 4.8 配对关系图：多变量交互关系分析

通过对多变量配对关系图的分析，揭示了各关键要素对混凝土强度的交互影响机制。首先，养护龄期表现出决定性的分层限制效应，图中清晰的颜色分层显示，早期样本（红色）受限于水化程度，即便拥有高水泥配比也难以达到高强度，而后期样本（蓝色）则占据了强度分布的顶端。



其次，在控制龄期变量后（即同一色系内），水泥含量与强度呈现显著的正相关，确立了其作为强度核心驱动力的地位；反之，用水量则呈现出符合“水胶比定则”的负相关趋势，过高的用水量明显抑制了混凝土后期的强度上限。

混凝土关键变量配对关系图




图 7 混凝土多变量交互关系分析配对关系图

## 5、实验总结

本次实验基于 Python 数据分析技术，成功实现了对混凝土原材料配比、养护龄期及强度测试等多源异构数据的全流程集成与分析。通过 Pandas 库完成属性模式对齐与逻辑记录连接，构建了包含 651 条完整记录的高质量宽表，并利用 Matplotlib 与 Seaborn 开展了多维度可视化探索。实验不仅验证了水泥含量与抗压强度的显著正相关性及强度的时效性演变规律，还揭示了水胶比及辅助材料分布的统计特征，最终打通了从数据获取、清洗融合到特征挖掘的完整链路，有效提升了利用数据科学解决复杂工程问题的综合实践能力。