



机器学习实验报告

分类实验

题目: 基于经典分类算法的乳腺肿瘤良恶性诊断

姓名: 汪君哲 许思源

时间: 2025-11-27

基于经典分类算法的乳腺肿瘤良恶性诊断

1 背景介绍

在机器学习研究领域中，经典监督分类算法（如逻辑回归、K 近邻、支持向量机和决策树等）以数学理论严谨、决策边界清晰以及对小样本数据的高效处理能力为主要优势，被广泛应用于医疗诊断、金融风控以及生物信息学分析。这些算法的核心思想在于基于明确的特征空间划分（如超平面分割或概率距离度量）和正则化策略，通过最小化分类误差并抑制过拟合来构建高泛化能力的判别模型。相比于参数庞大且难以解释的深度神经网络，传统分类模型的优势在于其特征权重直观反映了病理指标的临床重要性，便于医生理解和信任模型的判定逻辑，尤其在涉及生命健康安全、需要高可解释性的医学辅助诊断场景中表现出色。

乳腺癌作为全球女性发病率最高的恶性肿瘤之一，其早期发现与准确诊断对于制定治疗方案及提高患者生存率具有决定性意义。在传统的临床诊断中，病理学家通常依赖显微镜观察活检组织来判断肿瘤性质，这一过程不仅高度依赖医生的主观经验，且在面对复杂病例时耗时较长，存在一定的误诊风险。随着精准医疗和人工智能技术的飞速发展，将机器学习算法应用于医学影像数据的量化分析，构建计算机辅助诊断（CAD）系统，已成为辅助医生提高诊断效率与准确性的重要趋势。

因此，本项目以此为应用背景，采用著名的威斯康星乳腺癌诊断数据集（WDBC），包括肿瘤半径、纹理、平滑度、紧凑度及分形维数在内的 30 个高维数值特征。这些特征客观地反映了细胞核的形态学差异，是区分良性（Benign）与恶性（Malignant）肿瘤的关键依据。本研究旨在通过对这些特征进行深入的数据探索与预处理，利用机器学习分类算法（如逻辑回归、随机森林和支持向量机等）构建预测模型，挖掘数据背后的病理模式，从而实现乳腺癌良恶性的自动化、高精度分类，为临床医疗决策提供科学的数据支持。

2 实验过程

2.1 数据准备

为了完成这个任务，我们从 Kaggle（www.kaggle.com）上获取数据集。选取了浏览量和数据量较大的数据集“Breast Cancer Wisconsin (Diagnostic) Dataset”（<https://www.kaggle.com/datasets/khansaafreen/breastdataset>）。该数据集基于乳腺肿块细针穿刺（FNA）的数字图像，精确提取了包括肿瘤半径、纹理、平滑度、紧凑度及分形维数在内的 30 个高维数值特征。

在拿到数据后，我们先读取了数据的基本信息，该表格形状为(569, 31)，非编号数值

型数据列一共有 30 列，分别是

```
['diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean', 'area_mean',
 'smoothness_mean', 'compactness_mean', 'concavity_mean', 'concave points_mean',
 'symmetry_mean', 'fractal_dimension_mean', 'radius_se', 'texture_se', 'perimeter_se', 'area_se',
 'smoothness_se', 'compactness_se', 'concavity_se', 'concave points_se', 'symmetry_se',
 'fractal_dimension_se', 'radius_worst', 'texture_worst', 'perimeter_worst', 'area_worst',
 'smoothness_worst', 'compactness_worst', 'concavity_worst', 'concave points_worst',
 'symmetry_worst', 'fractal_dimension_worst']
```

编号数据列一共有 1 列，是

```
['id']
```

2.2 数据清洗

2.2.1 基础清洗与标签编码

首先，我们对 WDBC 原始数据集进行结构优化，剔除无物理意义的样本标识符（id）及因格式问题产生的无效列。完整性检查显示数据集无缺失值，保证了样本信息的连续性。

针对目标变量 `diagnosis`，采用二元编码处理，将恶性（Malignant）映射为 1，良性（Benign）映射为 0，从而将分类问题转化为标准的二分类数值计算任务。

2.2.2 基于 IQR 的异常值截断处理

为了缓解极端离群点对模型决策边界的扭曲，同时保留样本量，我们采用四分位距（Interquartile Range, IQR）法对连续型特征进行异常值检测与处理。对于任意特征 X ，首先计算其第一四分位数 Q_1 与第三四分位数 Q_3 ，进而得出四分位距 $IQR = Q_3 - Q_1$ 。


定义异常值的判定边界如下：

$$Lower_Bound = Q_1 - 1.5 \times IQR$$

$$Upper_Bound = Q_3 + 1.5 \times IQR$$

不同于直接剔除样本的传统做法，我们采用截断法（Clipping/Winsorization）处理异常值：将低于下界的数值替换为 `Lower_Bound`，高于上界的数值替换为 `Upper_Bound`。这种处理方式在抑制噪声干扰的同时，最大程度地保留了数据的分布特征，有效防止了信息丢失。处理后的箱线图显示，特征分布更加紧凑，极端偏离现象得到显著改善。

我们做了相关箱线图来直观的观察处理前后的差别：



在执行上述异常值阶段处理后：




图 2 异常值处理后的数据分布箱线图

可以看出，处理后离群点都消失了，处理效果良好。

2.2.3 特征标准化（Z-Score Standardization）

由于肿瘤半径（Radius）、面积（Area）及平滑度（Smoothness）等特征在物理量纲和数值数量级上存在巨大差异（例如面积均值可达 1000 以上，而平滑度仅为 0.1 左右），直接建模会导致基于距离或梯度的算法收敛困难。因此，我们采用 Z-Score 标准化方法，将所有特征映射至均值为 0、方差为 1 的标准正态分布。

对于特征向量 $\mathbf{x}$ 中的每一个观测值 x_i ，其变换公式为：

$$x'_i = \frac{x_i - \mu}{\sigma}$$

其中， μ 为样本均值， σ 为样本标准差。标准化消除了量纲影响，确保了所有特征在模型训练中具有同等的权重贡献。




图 3 标准化后的数据分布箱线图

可以看出，处理后每个变量都近似正态分布，且均值为 0，处理效果良好。

2.2.4 分层数据集划分

为了客观评估模型的泛化能力并防止类别不平衡导致的评估偏差，我们采用分层抽样（Stratified Sampling）策略进行数据集划分。




图 4 训练集和测试集分布图

我们将数据集按 7:3 的比例划分为训练集与测试集（`test_size=0.3`），并通过 `stratify` 参数锚定目标变量。这一操作确保了训练集与测试集中良恶性样本的比例（`Class Distribution`）与原始总体保持高度一致，从而保证了模型评估结果的统计学效力与公平性。

2.3 模型搭建

本实验旨在构建一个高效、鲁棒的乳腺肿瘤良恶性诊断系统。基于经标准化处理的 30 维病理特征数据，我们选取了 8 种具有代表性的监督学习分类算法进行建模。这些算法涵盖了 KNN、逻辑回归、支持向量机、朴素贝叶斯、树模型、集成学习方法以及神经网络（MLP），能够从不同维度挖掘数据的内在模式，并对这些模型的性能进行了对比。

2.3.1 基于距离的实例学习：K-近邻算法（KNN）

K-近邻算法（K-Nearest Neighbors, KNN）是一种经典的非参数化监督学习算法，其核心思想遵循“物以类聚”的自然规律。不同于逻辑回归或 SVM 需要通过训练阶段学习参数权重，KNN 在训练阶段仅存储样本数据，真正的计算发生在预测阶段。

当需要预测一个新的待测样本的类别时，算法会在特征空间中寻找与其距离最近的 K 个训练样本，并通过这 K 个邻居的类别来推断样本的类别。

KNN 的性能高度依赖于距离度量方式。在本实验中，处理后的特征空间为 30 维连续数值，因此采用标准的欧氏距离（Euclidean Distance）作为相似性度量。对于两个样本点 x 和 x_i ，其距离计算公式为：

$$d(x, x_i) = \sqrt{\sum_{j=1}^n (x^{(j)} - x_i^{(j)})^2}$$

其中， $n = 30$ 为特征维度， $x^{(j)}$ 表示第 j 个病理特征（如半径均值、纹理最差值等）的数值。

在构建 KNN 分类器时，超参数的选择对模型性能至关重要。基于乳腺癌数据集的特性，本实验在代码中进行了如下特定配置：

通常 K 值取奇数以避免投票平局，但本实验选择了较小的偶数 2。在医疗诊断场景下，恶性肿瘤的形态特征可能具有高度的特异性。选择较小的 K 值意味着模型对局部特征非常敏感，能够捕捉到特征空间中细微的病理模式，虽然这可能增加对噪声的敏感度，但配合距离加权策略可以有效缓解。

另外，传统的 KNN 采用“一人一票”的多数表决制，忽略了距离远近的影响。本实验采用了反距离加权（Inverse Distance Weighting）策略，即邻居对分类结果的贡献与其到待测样本的距离成反比。权重 w_i 定义为：

$$w_i = \frac{1}{d(x, x_i)}$$

这意味着，如果一个待测样本与某个恶性样本的距离极近（形态高度相似），即使其周围稍远处有良性样本，模型也会倾向于将其判定为恶性。这种策略在处理边界模糊的复杂病例时，能够显著提高诊断的灵敏度。

2.3.2 线性概率模型：逻辑回归（Logistic Regression）

逻辑回归是统计学与机器学习领域的经典基石。是一种处理二分类问题的广义线性模型（Generalized Linear Model）。不同于 KNN 基于几何距离的判定，逻辑回归旨在通过学习特征的权重，构建一个线性的决策边界（Decision Boundary）来分割良性与恶性样本。

逻辑回归的计算过程包含两个核心步骤：线性加权与非线性激活。

①**线性映射**：首先，模型对 30 个输入的病理特征 x 进行线性加权求和，引入偏置项 b ，得到线性输出 z ：

$$z = w^T x + b = w_1 x_1 + w_2 x_2 + \cdots + w_{30} x_{30} + b$$

其中， w 代表权重向量，直观地反映了每个特征（如“肿瘤半径”）对最终诊断结果的影响程度。

②**Sigmoid 激活**：为了将取值范围为 $(-\infty, +\infty)$ 的 z 转化为概率值，引入 Sigmoid 函数 $\sigma(z)$ ：

$$h_\theta(x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

该函数的输出 $h_\theta(x)$ 被解释为样本为恶性的条件概率 $P(y = 1|x)$ 。例如，若输出为 0.95，意味着模型认为该肿瘤有 95% 的可能性是恶性的。

③**参数优化**：为了找到最优的权重 w 和偏置 b ，模型通过梯度下降法最小化对数损失函数（Log-Loss / Cross-Entropy Loss）：

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\widehat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \widehat{y}^{(i)}) \right]$$

该损失函数具有凸函数性质，保证了优化算法能收敛到全局最优解。

在代码实现中，由于本数据集包含 30 个特征，且特征间可能存在多重共线性（例如半径、周长和面积高度相关），这会导致损失函数的曲面变得平坦，梯度下降收敛速度变慢，因此设计逻辑回归迭代次数为 5000。

同时加入了 L2 正则化（Ridge），正则化项 $\lambda \|w\|^2$ 能够限制权重 w 的数值过大，防止模型过度依赖某几个特征。在只有 569 个样本的小规模数据集上，这一机制对于防止过拟合（Overfitting）、提高模型在测试集上的泛化能力至关重要。

模型不仅给出“是/否”的硬分类，还给出概率值。对于处于 0.4-0.6 之间“模棱两可”的病例，医生可以重点关注，结合其他检查手段复核，这比单纯的二元预测更具临床

指导意义。

2.3.3 最大间隔分类：支持向量机（SVM）

支持向量机（Support Vector Machine, SVM）是统计学习理论中最稳健的分类算法之一。与逻辑回归试图寻找通过所有样本点的概率拟合不同，SVM 的核心目标是几何层面**的——寻找一个最优的决策超平面（Optimal Hyperplane），使得良性与恶性两类样本之间的间隔（Margin）最大化。

①**超平面定义**：在 30 维特征空间中，决策超平面可以表示为线性方程：

$$w^T x + b = 0$$

其中 w 是法向量，决定了超平面的方向， b 是位移项。

SVM 认为，只有那些位于类别边界上的“难分类样本”才是关键，这些样本被称为支持向量（Support Vectors）。为了获得最强的泛化能力（即对未知样本的容错率最高），算法需要在满足分类约束的前提下，最大化两类支持向量之间的垂直距离（即间隔 γ ）。

这等价于求解以下凸二次规划问题（Convex Quadratic Programming）：

$$\min_{w,b} \frac{1}{2} \|w\|^2, \text{ s.t. } y^{(i)}(w^T x^{(i)} + b) \geq 1, i = 1, 2, \dots, m$$

这种“最大间隔”机制为模型提供了一个安全缓冲区。在医疗诊断中，这意味着即使某个新样本的特征在一定范围内波动，只要未越过缓冲区，模型仍能做出稳定的正确判断。

在代码实现中，我们对 SVM 进行了特定的核函数配置，在这里首先选择了线性核。我们的数据集拥有 30 个特征。在高维空间中，样本点通常分布得较为稀疏，这使得在低维空间中纠缠不清的数据，在高维空间中往往变得线性可分。由于使用了线性核，该优化问题本质上是一个凸优化问题。这意味着我们找到的解一定是全局最优解，不存在局部最优陷阱。这为医疗诊断系统提供了极高的可靠性保证。

2.3.4 概率生成模型：朴素贝叶斯（Gaussian Naive Bayes）

朴素贝叶斯（Naive Bayes）是一类基于贝叶斯定理与特征条件独立假设的概率生成模型（Generative Model）。与逻辑回归或 SVM 直接学习分类边界（判别模型）不同，朴素贝叶斯试图通过学习数据在不同类别下的概率分布来进行推断。

该模型核心在于贝叶斯定理：对于给定的病理特征向量 x ，我们希望计算其属于恶性（Malignant, C_M ）的后验概率 $P(C_M|x)$ 。根据贝叶斯公式：

$$P(C_M|x) = \frac{P(x|C_M)P(C_M)}{P(x)}$$

其中， $P(C_M)$ 是先验概率*即不看任何特征时，样本为恶性的基础概率； $P(x|C_M)$ 是似然概率（即在已知是恶性肿瘤的情况下，出现该特征组合的可能性）。

直接计算联合概率 $P(x|C_M)$ 在高维空间中极其困难。因此，算法引入了一个强假设：特征之间相互独立。即假设肿瘤的半径、纹理、平滑度等特征互不影响。基于此，似然概率可以简化为各特征概率的连乘：

$$P(x|C_M) \approx \prod_{j=1}^{30} P(x_j|C_M)$$

由于本数据集的特征均为连续数值（而非文本分类中的词频），在数据处理后，每一维特征在特定类别下服从正态分布（高斯分布）。对于第 j 个特征，其概率密度函数为：

$$P(x_j|C_M) = \frac{1}{\sqrt{2\pi\sigma_y^2}} \exp\left(-\frac{(x_j - \mu_y)^2}{2\pi\sigma_y^2}\right)$$

其中， μ_y 和 σ_y^2 分别是训练集中恶性样本在该特征上的均值和方差。

该模型的训练过程实质上是统计学中的参数估计。它无需通过梯度下降进行迭代优化，只需简单地计算训练集中良性与恶性样本各特征的均值与方差。这意味着它的训练速度极快，计算复杂度远低于 SVM 和随机森林，且对小样本数据不太容易过拟合。

但其性能瓶颈主要源于“特征独立性假设”在生物学现实中的失效，在乳腺癌数据集中，许多特征存在天然的多重共线性（Multicollinearity）。例如：

radius_mean（半径）
perimeter_mean（周长）
area_mean（面积）

这三者在几何上是严格相关的，当这些高度相关的特征被视为“独立”并相乘时，相当于重复计算了同一信息，导致模型对某些特征的权重估计产生偏差，从而影响了最终的分类精度。

2.3.5 规则推理模型：决策树（Decision Tree）

决策树（Decision Tree）是一种模拟人类决策过程的树形结构分类模型。不同于逻辑回归或 SVM 依赖复杂的代数计算，决策树采用递归分割（Recursive Partitioning）策略，将复杂的特征空间切割成若干个互不重叠的矩形区域。

该模型具有极强的可解释性。它生成的一系列“若...则...”规则，能够直接被医生理解和验证，为临床诊断提供了宝贵的病理学依据。

在构建树的过程中，核心挑战在于“如何选择最优的分裂特征”。我们采用 CART（Classification and Regression Trees）算法，利用基尼不纯度（Gini Impurity）作为分裂准则。

假设当前节点包含 m 个样本，其中属于第 k 类（良性或恶性）的概率为 p_k ，则该节点的基尼不纯度定义为：

$$Gini(D) = 1 - \sum_{k=1}^K p_k^2$$

Gini 系数反映了从数据集中随机抽取两个样本，其类别标记不一致的概率。算法遍历所有 30 个特征及所有可能的切分点，寻找使得分裂后子节点加权 Gini 系数最小（即纯度最高）的特征进行分裂。这一过程不断递归，直到节点纯度达到阈值或树达到预设深度。决策树倾向于生长出过于复杂的枝叶以完美拟合训练数据，导致其对噪声极其敏感，泛化能力较弱。

2.3.6 集成学习模型：随机森林（Random Forest）

随机森林（Random Forest）是基于 Bagging（Bootstrap Aggregating）思想的集成学习算法，旨在解决单棵决策树过拟合与不稳定的缺陷。它通过构建大量的决策树，并将它们的预测结果进行汇总（多数投票）。

随机森林引入了双重随机性，使其成为机器学习中最强大的通用算法之一：

- 样本随机性（Bootstrap Sampling）：每棵树的训练集都是从原始数据中有放回地随机抽样生成的。这意味着每棵树看到的样本略有不同。
- 特征随机性（Feature Randomness）：在节点分裂时，算法不是在所有 30 个特征中寻找最优解，而是在随机选取的特征子集中寻找。

在代码实现中，我们构建了 100 棵相互独立的决策树。根据大数定律（Law of Large Numbers），随着树的数量增加，随机误差会相互抵消，模型的预测方差（Variance）会显著降低。实验表明，100 棵树足以覆盖特征空间中的主要模式，构建出平滑且鲁棒的非线性决策边界。

最终的分类结果由 100 棵树共同决定：

$$H(x) = \arg \max_Y \sum_{t=1}^{100} I(h_t(x) = Y)$$

其中 $I(\cdot)$ 为示性函数。只有当超过半数的树认为样本为恶性时，系统才做出恶性诊断。

虽然是模型可解释性不高，但随机森林可以通过统计某个特征在所有树中减少不纯度（Gini Impurity）的总量来评估特征重要性。这使得我们能够识别出哪些病理指标（如 `concave points_mean` 或 `area_worst`）是区分良恶性肿瘤的最关键因素，为病理学研究提供数据支持。

2.3.7 高效梯度提升框架：LightGBM

LightGBM（Light Gradient Boosting Machine）是分布式梯度提升框架。它基于 GBDT（Gradient Boosting Decision Tree）算法，但在处理速度和内存消耗上进行了革命性的优

化。其核心思想是采用加法模型（Additive Model），通过迭代的方式训练一系列弱分类器（决策树），每一棵新树都致力于拟合前一轮模型的残差（负梯度）。

假设模型由 K 棵树组成，对于第 i 个样本 x_i ，最终的预测输出 $\hat{y}_i$ 为所有树预测值的加和：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

其中 $\mathcal{F}$ 是决策树空间。

在第 t 轮迭代中，我们的目标是找到一棵新的树 $f_t(x)$ ，使得目标函数最小化：

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l\left(y_i, \widehat{y_i^{(t-1)}} + f_t(x_i)\right) + \Omega(f_t)$$

其中 l 为损失函数（二分类任务中使用对数损失 Log-loss）， Ω 为正则化项。

LightGBM 与传统 GBDT（如 XGBoost）最大的区别在于树的生长策略：

- Level-wise（按层生长）：同时分裂同一层的所有节点，容易产生不必要的叶子，效率较低。
- Leaf-wise（按叶子生长）：LightGBM 每次从当前所有叶子节点中，选择分裂增益（Split Gain）最大的那个节点进行分裂。

假设在某个节点 j 进行分裂，分裂增益 G_j 的近似计算公式（基于梯度的二阶展开）为：

$$G_j = \frac{1}{2} \left[\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma$$

其中， g_i 和 h_i 分别是一阶梯度和二阶海森矩阵（Hessian）， I_L 和 I_R 分别是左、右子节点的样本集合。Leaf-wise 策略能够更深入地生长决策树，在同样的裂变次数下，能显著降低模型偏差（Bias）。

在代码中，我们设置叶子节点数为 31，在二叉树中，31 个叶子大致对应深度 $depth \approx \log_2 31 \approx 5$ 。这既保证了模型有足够的非线性拟合能力，又防止了在仅有 569 个样本的数据集上出现过拟合。

2.3.8 深度学习基础：多层感知机（MLP）

多层感知机（Multi-Layer Perceptron, MLP）是一种前馈人工神经网络，它通过层级化的非线性变换，模拟人脑神经元的信息处理机制。根据 Universal Approximation Theorem，只要有足够的隐藏层神经元，MLP 理论上可以逼近任何复杂的连续函数。

本实验构建了一个包含两个隐藏层的神经网络。对于输入向量 $x \in R^{30}$ ：

- 第一隐藏层（64 个神经元）：

$$z^{[1]} = W^{[1]}x + b^{[1]}$$

$$a^{[1]} = \text{ReLU}(z^{[1]})$$

其中 $W^{[1]} \in \mathbb{R}^{64 \times 30}$ 为权重矩阵， $b^{[1]}$ 为偏置向量。

- 第二隐藏层（32 个神经元）：

$$z^{[2]} = W^{[2]}a^{[1]} + b^{[2]}$$

$$a^{[2]} = \text{ReLU}(z^{[2]})$$

此处将特征维度从 64 压缩至 32，迫使网络提取更高阶的抽象特征。

- 输出层（二分类）：

$$z^{[3]} = W^{[3]}a^{[2]} + b^{[3]}$$

$$\hat{y} = \sigma(z^{[3]}) = \frac{1}{1 + e^{-z^{[3]}}}$$

最终输出 $\hat{y}$ 为样本属于恶性肿瘤的概率。

Multi-Layer Perceptron (MLP) Architecture for Binary Classification




图 5 MLP 结构图

模型中使用了激活函数 RELU，数学定义为：

$$g(z) = \max(0, z)$$

相比于传统的 Sigmoid 或 Tanh 函数，ReLU 在 $z > 0$ 时导数恒为 1。这一特性有效地解决了深层网络中的梯度消失问题（Vanishing Gradient Problem），使得网络训练收敛速度更快。

模型通过最小化二元交叉熵损失（Binary Cross-Entropy Loss）来优化参数：

$$J(W, b) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\hat{y}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}) \right] + \frac{\alpha}{2} \|W\|_2^2$$

其中 $\frac{\alpha}{2} \|w\|_2^2$ 是代码中对应的 L2 正则化项，用于防止权重过大导致的过拟合。

具体来说，模型采用瓶颈式架构： $30 \rightarrow 64 \rightarrow 32 \rightarrow 1$ 。第一层升维（或适度扩宽）用于充分捕捉 30 个病理特征之间的非线性交互关系；第二层降维用于特征浓缩和去噪。模型中使用 Adam（Adaptive Moment Estimation）优化器，结合了动量法（Momentum）和 RMSProp 的优势。它分别为每个参数计算适应性学习率。参数更新规则涉及一阶矩估计 m_t 和二阶矩估计 v_t ：

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

这使得模型能够在复杂的损失曲面上快速找到全局最优解，而无需像 SGD 那样精细调节学习率。

2.4 模型训练测试

在完成 K 近邻（KNN）、逻辑回归、支持向量机（SVM）、朴素贝叶斯、决策树、随机森林、LightGBM 及深度学习模型（MLP）等多种分类算法的理论构建后，本节将详细阐述模型的具体训练流程、验证策略以及最终的性能评估方法。我们的目标是乳腺肿瘤良恶性（Malignant vs Benign）的诊断任务，从上述候选模型中筛选出泛化能力最强、且最符合临床安全要求的模型。

2.4.1 实验设置

为了客观评估模型在未见数据上的泛化能力，我们首先对经预处理的 WDBC 数据集进行了严格的划分。考虑到医疗数据中正负样本（良性与恶性）比例的重要性，我们摒弃了简单的随机划分，转而采用分层抽样（Stratified Sampling）策略。我们将数据集按 70/30 的比例划分为训练集和测试集，确保两部分数据中恶性肿瘤的比例保持一致，从而避免因分布偏差导致的评估失真。

超参数的选择决定了模型的上限。为了寻找最优的参数组合（如 SVM 的核函数类型、随机森林的树数量等），我们在训练集内部采用了 K 折交叉验证（K-Fold Cross-Validation）策略。具体而言，我们将训练集随机分为 K 个互斥子集，轮流将其中的 1 份作为验证数据，其余作为训练数据。该过程不仅能有效评估模型的稳定性。

鉴于癌症诊断的特殊性，单一的准确率指标不足以全面衡量模型性能。因此，我们选用以下核心指标构建多维度的评估体系：

① 准确率（Accuracy）

衡量模型预测正确的样本占总样本的比例，反映模型的整体判别能力。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

其中， TP 为真阳性， TN 为真阴性， FP 为假阳性， FN 为假阴性。

②精确率 (Precision)

表示在所有被预测为恶性的样本中，实际确实为恶性的比例。该指标高意味着误诊率（将良性误判为恶性）低。

$$\text{Precision} = \frac{TP}{TP + FP}$$

③召回率 (Recall)

表示在所有实际为恶性的样本中，被模型正确识别出来的比例。在医疗诊断中，该指标至关重要，因为漏诊可能导致患者错过最佳治疗窗口。

$$\text{Recall} = \frac{TP}{TP + FN}$$

④F1 分数 (F1-Score)

精确率与召回率的调和平均数，用于在两者之间寻求平衡，特别适用于处理类别不平衡问题。

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

⑤ROC 曲线下的面积 (ROC-AUC)

接收者操作特征曲线 (ROC Curve) 描绘了在不同分类阈值下，真正例率 (TPR) 与假正例率 (FPR) 之间的权衡关系。AUC (Area Under Curve) 值越接近 1，说明模型区分良恶性样本的能力越强，且不受特定阈值选择的影响。

$$\text{TPR} = \frac{TP}{TP + FN}$$

$$\text{FPR} = \frac{FP}{FP + TN}$$

$$\text{AUC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t))$$

2.4.2 模型训练流程

①Scikit-learn 库模型训练

基于 Scikit-learn 强大的机器学习生态，我们构建了涵盖经典统计学（如逻辑回归、SVM）至现代集成学习（LightGBM）及深度神经网络（MLP）的多元化分类模型库。遵循标准化的监督学习流程，我们首先将经 StandardScaler 归一化处理后的训练数据输入模型，通过调用统一的.fit()接口执行参数拟合，旨在让各算法从 30 维病理特征中自动习得区分良恶性肿瘤的非线性映射关系与决策边界；这一过程不仅实现了不同数学机理模型（如距离度量、超平面分割、梯度提升）的并行训练，更为后续基于独立测试集的 F1-分数、ROC/AUC 等性能对比与临床适用性评估奠定了坚实的计算基础。

```
models_dict = {
    # 1. K 近邻 (KNN): 通过计算样本间距离进行分类
    "KNN": KNeighborsClassifier(n_neighbors=2, weights='distance'),
    # 2. 逻辑回归: 线性分类模型
    "逻辑回归": LogisticRegression(random_state=42, max_iter=5000),
    # 3. 支持向量机 (SVM): 寻找最优分类超平面
    "支持向量机": SVC(kernel='linear', random_state=42, probability=True),
    # 4. 决策树: 基于特征阈值的树形分类规则
    "决策树": DecisionTreeClassifier(random_state=42),
    # 5. 随机森林: 集成多个决策树
    "随机森林": RandomForestClassifier(random_state=42, n_estimators=100),
    # 6. 朴素贝叶斯: 基于贝叶斯定理的概率分类器
    "朴素贝叶斯": GaussianNB(),
    # 7. LightGBM: 基于直方图的高效梯度提升框架
    "LightGBM": lgb.LGBMClassifier(
        n_estimators=100,      # 树的数量
        learning_rate=0.1,    # 学习率
        num_leaves=31,        # 叶子节点数 (控制复杂度)
        random_state=42,
        verbosity=-1          # 静默模式
    ),
    # 8. 神经网络 (MLP): 基于反向传播的多层感知机
    "神经网络 (MLP)": MLPClassifier(
        hidden_layer_sizes=(64, 32), # 网络结构: 输入->64->32->输出
        activation='relu',          # 激活函数
        solver='adam',              # 优化器
        alpha=0.0001,               # L2 正则化系数
        max_iter=1000,              # 最大迭代次数
        random_state=42
    )
}
```

②手写模型训练

我们挑选了两个效果较好的经典分类模型——**SVM** 和 **随机森林**——进行手写实现。为了验证我们**手动编写**的模型（SimpleSVM、SimpleRandomForest 等）的正确性，我们在标

准化后的数据上进行训练和评估，并将其结果与库函数的表现进行对比。这确保手动实现的优化逻辑（如闭式解或坐标下降）与 Scikit-learn 一致，支持算法机制的深入理解。

2.5 结果可视化

首先我们统计了 Scikit-learn 库模型在训练集和测试集上的 Accuracy、Precision、Recall 和 F1-Score（表 1）：

表 1 测试集上 Accuracy、Precision、Recall 和 F1-Score 统计表

模型	Accuracy	Precision	Recall	F1-Score
KNN	0.9532	0.9516	0.9219	0.9365
逻辑回归	0.9708	0.9836	0.9375	0.9600
SVM	0.9766	0.9839	0.9531	0.9683
决策树	0.9357	0.9492	0.8750	0.9106
随机森林	0.9708	1.0000	0.9219	0.9593
朴素贝叶斯	0.9474	0.9661	0.8906	0.9268
LightGBM	0.9708	1.0000	0.9219	0.9600
多层感知机	0.9766	1.0000	0.9375	0.9677

综合所有 8 个模型的表现，SVM 与 MLP 表现最强，以 97.66% 的准确率并列第一，但二者适用场景略有不同：SVM 因拥有全场最高的召回率（95.31%）和 F1-Score，漏诊最少，是医疗筛查的最佳选择；而 MLP（以及随机森林和 LightGBM）则实现了 100% 的精确率（零误报），在保持高准确率的同时杜绝了虚惊一场，更适合用于精准确诊的场景。

我们还比较了 6 种传统机器学习方法的准确率：




图 6 传统机器学习方法准确率条形图




图 7 传统机器学习方法混淆矩阵

随后我们运行了手写的 SVM 和随机森林模型，并于调用 Scikit-learn 库训练的模型进行对比。




图 8 手写 SVM 的训练 Loss 曲线

首先我们统计了 Scikit-learn 库模型和手写模型在训练集和测试集上的 Accuracy、Precision、Recall 和 F1-Score 对比（表 2）：

表 2 手写模型和调库模型在测试集上的数据统计表

模型	Accuracy(调库)	Accuracy(手写)	差值
SVM	0.9766	0.9766	0
随机森林	0.9708	0.9766	0.0058

发现二者性能相近。




图 8 手写算法和 sklearn 库模型性能对比图

2.6 分析和优化

2.6.1 模型结果分析

根据表 1 及图 6 的量化评估结果显示，不同算法在乳腺癌诊断任务中呈现出显著的性能分层与功能分化。支持向量机（SVM）与多层感知机（MLP）以 97.66% 的准确率并列榜首，代表了本实验线性分类与非线性拟合的最高水平。然而，深入剖析精确率（Precision）与召回率（Recall）的制衡关系发现，SVM 展现出对恶性肿瘤极高的敏锐度（Recall=95.31%），这意味着其漏诊率极低，能够最大限度地捕捉潜在病患，这正是癌症初筛阶段（Screening）最核心的诉求；相比之下，随机森林、LightGBM 与 MLP 则实现了惊人的 100% 精确率，即模型一旦报警则必为恶性，完全杜绝了假阳性带来的医疗资源浪费与患者心理负担，这使其更适用于确诊复核（Confirmation）场景。此外，集成算法（随机森林、LightGBM）相比单一决策树（Accuracy 93.57%）的显著提升，再次验证了通过 Bagging 或 Boosting 策略降低模型方差、抑制过拟合的有效性。

表 2 与图 8 的对比分析为理解机器学习算法的底层机制提供了有力证据。手动实现的

SVM 模型与 Scikit-learn 库模型在测试集上的准确率完全一致（均为 97.66%），且差值为 0，结合图 8 中平滑收敛的训练 Loss 曲线，充分证明了我们基于拉格朗日对偶性与梯度上升法推导的优化逻辑是完全正确的，成功复现了工业级算法的核心能力。有趣的是，手写版随机森林在测试集上甚至微弱领先库模型（+0.58%）。这并非说明手写版算法更优，而是揭示了随机森林算法固有的随机性特征——由于 Bootstrap 抽样与特征选择的随机种子不同，即使是简化的手写逻辑，在特定数据划分下也可能捕获到更具鲁棒性的特征组合。这一对比实验不仅验证了代码的正确性，更通过“白盒化”的实现过程，消除了我们对机器学习库函数的盲目依赖，深化了对算法内部参数对最终性能影响的理解。




图 9 随机森林特征重要性排序图

2.6.2 模型优化

在基础模型对比实验中，SVM 与随机森林表现优异。为进一步挖掘模型潜力，我们实施了针对性的深度优化策略：一是为 SVM 引入非线性核函数（RBF）并手动实现基于对偶梯度上升的求解算法；二是利用随机森林的特征重要性评估机制，进行特征选择（Feature Selection），旨在构建更轻量、更高效的诊断模型。

①SVM 的非线性扩展与算法实现

针对原始线性 SVM 可能无法充分捕捉复杂生物标志物非线性交互的问题，我们设计并手动实现了一个支持高斯径向基函数（RBF Kernel）的 SVM 分类器。

我们通过拉格朗日乘子法求解 SVM 的对偶问题（Dual Problem），利用 RBF 核函数将低维特征映射至无限维空间：

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

优化过程采用投影梯度上升法（Projected Gradient Ascent），直接对拉格朗日乘子 α 进行迭代更新，同时满足 KKT 条件约束 $0 \leq \alpha_i \leq C$ 。




图 10 手写 SVM (RBF) 的训练 Loss 曲线

②随机森林特征筛选与模型瘦身

为了解决高维医疗数据中普遍存在的特征冗余（Redundancy）问题，我们利用全特征随机森林模型计算了特征的基尼重要性（Gini Importance），并实施了递归特征消除（RFE）实验。

乳腺癌数据集包含“半径”、“周长”、“面积”等几何相关的特征组，物理意义上存在高度的多重共线性。全特征模型虽然信息全，但也引入了噪声。因此我们测试了从 Top-5 到 Top-30 不同特征子集的模型表现。




图 11 随机森林特征筛选折线图

我们成功构建了一个“瘦身版”随机森林模型（Top-20 Features）。该模型在丢弃了 33%（10 个）冗余特征的情况下，性能反而提升了 1.17%。这不仅验证了“少即是多（Less is More）”的特征工程原则，也为临床实际应用提供了指导——即只需采集 20 个关键指标，即可达到甚至超越全套检查的诊断精度，从而降低检测成本和时间。

表 3 优化模型在测试集上的数据统计表

模型	Accuracy	Precision	Recall	F1-Score
SVM(RBF)	0.9825	1.0000	0.9531	0.9760
SVM	0.9766	0.9839	0.9531	0.9683
Top-20 Features 随机森林	0.9825	0.9833	0.9365	0.9593
随机森林	0.9708	1.0000	0.9219	0.9593

同时，我们还将这两个优化模型和较为先进的 LightGBM 和 MLP 进行对比：

观察图中的模型混淆矩阵（图 12），可以发现一个显著的共性：所有高阶模型在“误报率”控制上均达到了极致，假阳性（False Positive）数量几乎全部收敛为 0。这意味着如果模型判定为恶性，其临床可信度接近 100%，极大地避免了因误诊导致的患者恐慌和过度医疗。然而，在医疗诊断最核心的“漏诊率”指标上，模型间拉开了差距。手写 SVM（RBF）表现出最强的敏锐度，仅漏诊了 3 例恶性样本（FN=3），相比之下，基于树模型的随机森林和 LightGBM 均漏诊了 5 例。这一微小的差距在 AUC 得分上得到了放大验证，SVM 以 0.99825 的极高 AUC 值位居榜首。这表明在处理处于“良恶性边界”的模糊病例时，基于 RBF 核的 SVM 决策边界更为精准，能够挖掘出其他模型遗漏的细微病理特征。




图 12 优化方法混淆矩阵




图 13 优化方法 ROC 曲线

虽然 LightGBM 和 MLP 代表了工业界最前沿的 Boosting 框架和深度学习技术，但在仅有 569 个样本的数据集上，它们并未展现出压倒性优势，反而略逊于经过 RBF 核优化的 SVM。这是因为深度学习和梯度提升树通常需要海量数据来拟合其庞大的参数空间，而在小样本高维空间 ($N = 569, D = 30$) 中，SVM 凭借其最大间隔 (Max Margin) 的几何特性和核技巧 (Kernel Trick) 对非线性流形的映射能力，展现出了更优越的泛化性能。最终，SVM (RBF) 以 98.25% 的准确率和 0.9982 的 AUC 性能最佳，证明了针对特定数据分布选择合适的核函数，比盲目堆砌复杂模型更为关键。

3 总结

本实验基于威斯康星乳腺癌数据集，通过严格的数据预处理与分层抽样，系统评估了从经典统计学 (KNN、逻辑回归、朴素贝叶斯、SVM、决策树) 到前沿集成学习与深度学习 (随机森林、LightGBM、MLP) 共 8 种模型的诊断性能。实验结果表明，手写实现的 RBF 核支持向量机 (SVM) 展现出最佳的泛化能力，以 98.25% 的准确率和 0.9982 的 AUC 值位居榜首，实现了零误报 (Precision=100%) 且漏诊率全场最低 (仅 3 例)。与之相比，虽然 LightGBM 和 MLP 等复杂模型表现优异，但在本实验的小样本高维数据环境下，并未超越经过核函数优化的 SVM，证明了最大间隔分类器在处理此类医疗数据时的鲁棒性。

此外，基于随机森林的特征重要性分析验证了“少即是多”的原则，仅保留 Top-20 关键特征的模型反而在精度上超越了全特征模型 (提升至 98.25%)，有效去除了数据噪声。

综上所述，SVM (RBF 核) 凭借其在召回率 (筛查需求) 与精确率 (确诊需求) 上的完美平衡，确立为本研究中理想的乳腺癌辅助诊断方案，同时也揭示了在医疗诊断场景中，针对数据特性选择合适的算法内核比盲目追求模型复杂度更为关键。

4 组员及任务分配情况

：数据处理，SVM 和随机森林优化，模型对比和可视化，实验报告撰写。

许思源：数据处理，手写实现 SVM 和随机森林，模型优化，可视化。

汪君哲：数据处理，利用 scikit-learn 进行模型搭建，结果分析，可视化。

参考文献

[1] Ganganwar V. An overview of classification algorithms for imbalanced datasets[J]. International Journal of Emerging Technology and Advanced Engineering, 2012, 2(4): 42-47.

- [2] Charbuty B, Abdulazeez A. Classification based on decision tree algorithm for machine learning[J]. Journal of Applied Science and Technology Trends, 2021, 2(1): 20-28.
- [3] Taunk K, De S, Verma S, et al. A brief review of nearest neighbor algorithm for learning and classification[C]//2019 International Conference on Intelligent Computing and Control Systems (ICCS). IEEE, 2019.
- [4] Tharwat A. Classification assessment methods[J]. Applied Computing and Informatics, 2021, 17(1): 168-192.
- [5] Song Y Y, Lu Y. Decision tree methods: applications for classification and prediction[J]. Shanghai Archives of Psychiatry, 2015.