



机器学习实验报告

聚类实验

题目： 基于 Dry Bean 数据集的聚类分析

姓名： 汪君哲 许思源

时间： 2025-12-20

基于 Dry Bean 数据集的聚类分析

1 背景介绍

在机器学习研究领域中，聚类分析作为无监督学习的核心方法之一，其重要性在于能够在没有标签指导的情况下自动发现数据的内在结构与模式。与监督学习依赖标注数据不同，聚类算法通过度量样本间的相似性（如欧氏距离、余弦相似度等）和优化目标函数（如簇内紧密度与簇间分离度的平衡），实现对数据的自动分组。经典聚类算法（如 K-Means、层次聚类和 DBSCAN 等）以其数学原理清晰、计算效率高以及对不同数据分布的适应能力为主要优势，被广泛应用于市场细分、生物信息学分析、图像分割以及异常检测等领域。这些算法的核心思想在于基于明确的距离度量和聚类准则，通过迭代优化或密度连接来构建具有良好可解释性的数据划分模型。

农产品的自动化分类与质量控制是现代农业智能化发展的重要方向之一。传统的农产品分选主要依赖人工目视检查，这一过程不仅效率低下、主观性强，且在面对大批量产品时难以保证分类的一致性和准确性。随着计算机视觉和机器学习技术的快速发展，基于几何形态特征的自动分类系统已成为提升农产品分拣效率与质量控制水平的关键技术手段。通过提取产品的形状、大小、纹理等客观量化特征，利用聚类算法发现不同品种或等级间的自然分组模式，可以实现无需人工标注的智能分类，显著降低人力成本并提高分类的客观性。

因此，本项目以农业应用为背景，采用著名的 Dry Bean Dataset（干豆数据集），该数据集包含 7 种不同类型干豆（DERMASON、SIRA、SEKER、HOROZ、CALI、BARBUNYA、BOMBAY）的 16 个几何形态特征。本研究旨在通过对这些高维几何特征进行深入的探索性数据分析与标准化预处理，利用多种经典聚类算法（包括 K-Means、层次聚类和 DBSCAN）构建无监督分类模型，并通过内部评价指标（轮廓系数、Calinski-Harabasz 指数、Davies-Bouldin 指数）和外部评价指标（调整兰德指数 ARI、归一化互信息 NMI）进行系统性评估。

此外，本实验还创新性地设计了自定义聚类视角，分别从“大小形态特征”和“形状因子特征”两个维度进行聚类分析，探索不同特征子集对聚类结果的影响，挖掘数据背后的多维度分组模式。通过算法对比、参数优化以及手写实现与库函数的对比验证，本研究不仅实现了对豆类的自动化、高精度聚类分析，更深入理解了聚类算法的原理与应用，为农产品智能分选系统的开发提供了科学的方法论支持和实证依据。

2 实验过程

2.1 数据准备

为了完成这个任务，我们从 Kaggle (www.kaggle.com) 上获取数据集。选取了浏览量和

数据量较大的数据集“Dry Bean Dataset”(<https://www.kaggle.com/datasets/sansuthi/dry-bean-dataset>)。该数据集包含 7 种不同类型干豆 (DERMASON、SIRA、SEKER、HOROLZ、CALI、BARBUNYA、BOMBAY) 的 16 个几何形态特征。这些特征客观地反映了豆类的面积、周长、长轴长度、短轴长度、长宽比、离心率、凸包面积、等效直径、范围、实心度、圆度、紧致度及四个形状因子等形态学差异，是区分不同豆类品种的关键依据。

样本数量：13,611 条记录（去重后 13,543 条）

数据质量：无缺失值，数据完整性良好

在拿到数据后，我们先读取了数据的基本信息，该表格形状为(13611, 17)，7 个大豆品种，具体 16 个特征如下：

Area: 豆子区域面积
Perimeter: 豆子周长
MajorAxisLength: 最长轴长度
MinorAxisLength: 最短轴长度
AspectRatio: 长宽比
Eccentricity: 离心率
ConvexArea: 凸包面积
EquivDiameter: 等效直径
Extent: 范围
Solidity: 实心度
Roundness: 圆度
Compactness: 紧致度
ShapeFactor1-4: 形状因子 1-4

标签列一共有 1 列，是“Class: 豆子类别”。




图 1 数据集类别分布

2.2 数据清洗

2.2.1 基础清洗与标签编码

首先，缺失值是数据质量问题中最常见的情况之一，我们对该数据集进行完整性检查，显示数据集无缺失值，保证了样本信息的连续性。重复值检测发现 68 行完全重复的记录（占总样本的 0.50%），删除重复行后数据维度为(13,543, 17)。

将数据集分为特征矩阵 X 和标签向量 y ：

$$X \in \mathbb{R}^{n \times d}, \quad y \in \{0, 1, 2, \dots, K-1\}^n$$

其中： $n = 13,543$ ：样本数量； $d = 16$ ：特征维度； $K = 7$ ：类别数量。

原始类别标签为字符串类型（如“DERMASON”“SIRA”等），需要转换为数值型编码以便后续计算，编码映射关系如下：

表 1 编码映射关系表

原始标签	数值编码	样本数量
BARBUNYA	0	1322
BOMBAY	1	522
CALI	2	1630
DERMASON	3	3546
HOROZ	4	1928
SEKER	5	2027
SIRA	6	1636

标签编码后，类别向量 y 变为整数序列，便于计算外部评价指标（如 ARI、NMI）时进行数值比较。

2.2.2 特征标准化

观察原始特征的统计量分布：

表 2 初始特征统计量分布（仅列举部分特征）

特征类型	最小值	最大值	均值	标准差
Area	20420	254616	53048	29324
Perimeter	524.74	1985.37	855.28	214.19
Eccentricity	0.219	0.911	0.751	0.092

续表 2

特征类型	最小值	最大值	均值	标准差
ShapeFactor1	0.0014	0.0024	0.0017	0.0006

可以看出，不同特征的量纲差异极大：Area 的数值在 10^4 量级，而 ShapeFactor 的数值在 10^{-3} 量级。在基于距离的聚类算法（如 K-Means、层次聚类）中，欧氏距离计算公式为：

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^d (x_{ik} - x_{jk})^2}$$

若不进行标准化，Area 特征由于数值范围大，其贡献将占据距离计算的主导地位，导致其他重要特征（如形状因子）的影响被完全掩盖，严重影响聚类效果。

因此，我们采用 Z-Score 标准化方法，将所有特征映射至均值为 0、方差为 1 的标准正态分布。

对于特征向量 $\mathbf{x}$ 中的每一个观测值 x_i ，其变换公式为：

$$x'_i = \frac{x_i - \mu}{\sigma}$$

其中， μ 为样本均值， σ 为样本标准差。标准化消除了量纲影响，确保了所有特征在模型训练中具有同等的权重贡献。




图 2 标准化前后特征数值分布对比统计图（仅列举部分特征）

从结果可以看出：所有特征的均值已接近于 0（浮点误差范围内），所有特征的标准差均精确等于 1，数据分布形态保持不变，仅进行了线性缩放平移。

2.2.4 主成分分析（PCA）降维

主成分分析（Principal Component Analysis, PCA）通过线性变换将原始特征投影到方差最大的方向上，实现降维的同时保留尽可能多的信息。

假设标准化后的数据矩阵为 $\mathbf{X} \in \mathbb{R}^{n \times d}$ ，PCA 的目标是找到 k 个正交单位向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_k$ （主成分方向），使得投影后数据的方差最大。

第一主成分方向 $\mathbf{w}_1$ 的求解问题为：

$$\mathbf{w}_1 = \arg \max_{|\mathbf{w}|=1} \text{Var}(\mathbf{X}\mathbf{w}) = \arg \max_{|\mathbf{w}|=1} \mathbf{w}^T \Sigma \mathbf{w}$$

其中 $\Sigma = \frac{1}{n} \mathbf{X}^T \mathbf{X}$ 为协方差矩阵。

通过求解协方差矩阵的特征值分解：

$$\Sigma = \mathbf{W} \Lambda \mathbf{W}^T$$

其中： $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_d]$ ：特征向量矩阵（主成分方向）； $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ ：特征值对角矩阵， $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$

选择前 k 个最大特征值对应的特征向量，即可得到降维后的数据：

$$\mathbf{X}_{PCA} = \mathbf{X} \mathbf{W}_k \in \mathbb{R}^{n \times k}$$




图 3 PCA 后的数据分布

选择前 k 个最大特征值对应的特征向量，即可得到降维后的数据：

第 i 个主成分的方差解释率为：

$$\rho_i = \frac{\lambda_i}{\sum_{j=1}^d \lambda_j}$$

表示该主成分保留了原始数据方差的百分比。在本数据集中，各主成分的方差解释率为 PC1: 55.55%、PC2: 26.36%、累计方差解释率 81.91%。

2.3 模型搭建

聚类分析作为无监督学习的核心方法，旨在根据数据样本之间的相似性将其划分为不同的组（簇），使得同一簇内的样本尽可能相似，不同簇间的样本尽可能不同。本实验选择了三种经典且原理互补的聚类算法进行对比实验：**K-Means（基于划分）**、**层次聚类 Agglomerative Clustering（基于层次）**和**DBSCAN（基于密度）**。这三种算法分别代表了聚类方法的不同思想流派，各有优劣，适用于不同的数据分布和应用场景。

2.3.1 K-Means 聚类算法

K-Means 是最经典的基于划分的聚类算法，由 MacQueen 于 1967 年提出。其核心思想是通过迭代优化的方式，将 n 个样本划分为 K 个簇，使得每个样本属于距其最近的簇中心（质心），并最小化簇内平方误差和（Within-Cluster Sum of Squares, WCSS）。

目标函数：

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} |x_i - \mu_k|^2, \quad \mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$$

其中， K 是簇的数量（超参数，需预先指定）， C_k 是第 k 个簇的样本集合， μ_k 是第 k 个簇的质心（均值向量）， $|x_i - \mu_k|$ 是样本 x_i 到质心 μ_k 的欧氏距离

算法流程如下：

- ①初始化：随机选择 K 个样本作为初始簇中心 $\{\mu_1^{(0)}, \mu_2^{(0)}, \dots, \mu_K^{(0)}\}$
- ②分配步骤（E-step）：将每个样本分配到距离最近的簇中心：

$$C_k^{(t)} = \{x_i : |x_i - \mu_k^{(t)}| \leq |x_i - \mu_j^{(t)}|, \forall j \neq k\}$$

- ③更新步骤（M-step）：重新计算每个簇的质心：

$$\mu_k^{(t+1)} = \frac{1}{|C_k^{(t)}|} \sum_{x_i \in C_k^{(t)}} x_i$$

④迭代终止条件：重复步骤 2-3，直到满足以下任一条件：质心不再变化： $|\mu_k^{(t+1)} - \mu_k^{(t)}| < \varepsilon$ （ ε 为收敛阈值）、达到最大迭代次数或目标函数 J 的变化小于阈值

K-means 计算效率高，时间复杂度为 $O(n \cdot K \cdot d \cdot t)$ ，其中 t 为迭代次数，适合大规模数据，算法逻辑清晰，易于理解和实现，还可以通过并行化、Mini-Batch 等技术进一步提升效率

但同样存在缺点，例如，需要预先指定 K 值，簇数选择不当会严重影响聚类效果；而且对初始化敏感，不同的初始质心可能导致不同的局部最优解；只适合球形簇，对非凸形状的簇效果较差。

2.3.2 层次聚类算法 (Agglomerative Clustering)

层次聚类 (Hierarchical Clustering) 是一种基于层次结构的聚类方法，分为自顶向下 (分裂式) 和自底向上 (凝聚式) 两种策略。本实验采用的 Agglomerative Clustering (凝聚式层次聚类) 属于后者，其核心思想是：初始时将每个样本视为一个独立的簇，然后逐步合并距离最近的簇对，直到达到指定的簇数或所有样本合并为一个簇。

算法流程如下：

- ①初始化：将 n 个样本分别作为 n 个独立的簇：

$$\mathcal{C}^{(0)} = \{\{x_1\}, \{x_2\}, \dots, \{x_n\}\}$$

- ②计算簇间距离：对于任意两个簇 C_i 和 C_j ，根据连接方式 (linkage) 计算距离 $d(C_i, C_j)$ 。

- ③合并最近簇对：找到距离最小的两个簇并合并：

$$(C_i^*, C_j^*) = \arg \min_{i \neq j} d(C_i, C_j)$$

$$C_{\text{new}} = C_i^* \cup C_j^*$$

- ④更新簇集合：

$$\mathcal{C}^{(t+1)} = \mathcal{C}^{(t)} \setminus \{C_i^*, C_j^*\} \cup \{C_{\text{new}}\}$$

- ⑤迭代终止：重复步骤 2-4，直到簇的数量减少到指定的 K 个

簇间距离的计算方式 (Linkage) 有以下几种，不同的连接方式定义了不同的簇间距离度量标准，显著影响聚类结果：

- 单连接 (Single Linkage)

$$d_{\text{single}}(C_i, C_j) = \min_{x \in C_i, y \in C_j} |x - y|$$

特点：倾向于产生链状簇，对噪声敏感。

- 全连接 (Complete Linkage)

$$d_{\text{complete}}(C_i, C_j) = \max_{x \in C_i, y \in C_j} |x - y|$$

特点：倾向于产生紧凑的球形簇，抗噪声能力强。

- 平均连接 (Average Linkage)

$$d_{\text{average}}(C_i, C_j) = \frac{1}{|C_i| \cdot |C_j|} \sum_{x \in C_i} \sum_{y \in C_j} |x - y|$$

特点：折中方案，综合考虑簇内所有样本对。

- Ward 连接 (Ward Linkage)

$$d_{\text{ward}}(C_i, C_j) = \frac{|C_i| \cdot |C_j|}{|C_i| + |C_j|} |\mu_i - \mu_j|^2$$

其中 μ_i, μ_j 分别为两簇的质心。

特点：最小化合并后的簇内方差增量，适合球形簇，与 K-Means 目标函数类似。

该算法不需要预先指定簇数，可以通过树状图（Dendrogram）灵活选择切分层次，生成的层次结构树直观展示簇的合并过程，适应多种数据分布，可以通过选择不同的 linkage 方式适应不同簇形状。但计算复杂度高，时间复杂度为 $O(n^2 \log n)$ 到 $O(n^3)$ ，不适合大规模数据。而且一旦两簇合并，无法回退，可能导致早期错误合并影响最终结果

2.3.3 DBSCAN 聚类算法

DBSCAN（Density-Based Spatial Clustering of Applications with Noise）是由 Ester 等人于 1996 年提出的基于密度的聚类算法。与 K-Means 和层次聚类不同，DBSCAN 不需要预先指定簇数，能够发现任意形状的簇，并能自动识别噪声点（离群点）。

该算法有以下核心概念：

- ϵ -邻域：样本 x 的 ϵ -邻域定义为：

$$N_{\epsilon}(x) = \{x' \in \mathcal{D} : |x - x'| \leq \epsilon\}$$

- 核心点（Core Point）：若样本 x 的 ϵ -邻域内至少有 MinPts 个样本，则 x 为核心点：

$$|N_{\epsilon}(x)| \geq \text{MinPts}$$

- 边界点（Border Point）：不是核心点，但位于某个核心点的 ϵ -邻域内的样本。
- 噪声点（Noise Point）：既不是核心点，也不是边界点的样本，标记为 -1。
- 密度可达（Density-Reachable）：若存在样本序列 $x_1, x_2, \dots, x_n$ ，其中 $x_1 = p$ 、 $x_n = q$ ，且对于 $i = 1, \dots, n-1$ ， x_{i+1} 在 x_i 的 ϵ -邻域内，且 x_i 为核心点，则称 q 从 p 密度可达。
- 密度相连（Density-Connected）：若存在样本 o ，使得 p 和 q 都从 o 密度可达，则称 p 和 q 密度相连。

算法流程如下

- ①初始化：将所有样本标记为“未访问”。
- ②遍历样本：对每个未访问的样本：标记为“已访问”，计算其 ϵ -邻域 $N_{\epsilon}(x)$ 。

若 $|N_{\epsilon}(x)| < \text{MinPts}$ ，暂时标记为噪声点。

若 $|N_{\epsilon}(x)| \geq \text{MinPts}$ ，创建新簇并扩展。

- ③簇扩展（广度优先搜索）：

将 x 的所有邻域内样本加入队列，对队列中的每个样本 x' ：若 x' 未访问，标记为已访问并计算其邻域；若 x' 也是核心点，将其邻域内样本加入队列；若 x' 尚未归属任何簇，将其加入当前簇。

- ④簇形成：所有密度相连的核心点及其边界点构成一个簇。

$$C_k = \{x: x \text{ 与某核心点 } p \in C_k \text{ 密度相连}\}$$

该算法不需要预先指定簇数：根据数据密度自动确定簇的数量，适合非凸形、环形等复杂形状的簇，会将低密度区域的样本标记为噪声（label 为-1）。

但这个模型同样对参数敏感： ϵ 和MinPts的选择直接影响聚类结果，需根据数据分布调整。同时，在高维空间中，距离度量失效（维度灾难），难以定义有意义的密度。朴素实现的时间复杂度为 $O(n^2)$ ，需要空间索引（如 KD-Tree）优化。

2.4 模型训练测试

在完成 K-Means、层次聚类和 DBSCAN 等多种聚类算法的理论构建后，本节将详细阐述模型的具体训练流程、验证策略以及最终的性能评估方法。我们的目标是将不同种类的大豆进行聚类分析，综合评价模型聚类结果的轮廓系数、CH 指数、DB 指数、ARI、NMI，从上述候选模型中筛选出聚类能力最强的模型。

2.4.1 实验设置

为了系统性地评估三种聚类算法在 Dry Bean 数据集上的性能表现，我们设计了严格的实验方案。与监督学习不同，聚类作为无监督学习任务，其评估体系更加多元化，既需要考察算法发现数据内在结构的能力（内部指标），也需要在已知真实类别的情况下验证聚类结果与真实分布的一致性（外部指标）。本节将详细阐述实验的数据划分策略、参数优化方法以及多维度评价指标体系的构建。

聚类质量的评估是一个多维度、多视角的问题。单一指标难以全面反映算法性能，因此我们构建了涵盖内部指标和外部指标的综合评价体系。内部指标基于聚类结果本身，不依赖真实标签，主要衡量簇内的紧密度和簇间的分离度。外部指标需要已知真实类别标签，通过比较聚类结果与真实标签的一致性来评估算法性能。

①轮廓系数（Silhouette Coefficient）

轮廓系数衡量样本与所属簇的相似度以及与邻近簇的差异度，取值范围为 $[-1,1]$ ，值越大表示聚类效果越好。

对于样本 x_i ，其轮廓系数定义为：

$$s(x_i) = \frac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}$$

其中：

$a(x_i) = \frac{1}{|C_i|-1} \sum_{x_j \in C_i, j \neq i} |x_i - x_j|$ ：样本 x_i 与同簇内其他样本的平均距离（簇内不相似）。

$b(x_i) = \min_{k \neq i} \left(\frac{1}{|C_k|} \sum_{x_j \in C_k} |x_i - x_j| \right)$ ：样本 x_i 与最近邻簇内所有样本的平均距离（簇间不相似）。

相似度)。

整体轮廓系数为所有样本轮廓系数的平均值：

$$\text{Silhouette} = \frac{1}{n} \sum_{i=1}^n s(x_i)$$

② Calinski-Harabasz 指数 (CH Index)

CH 指数 (也称方差比准则) 通过比较簇间离散度与簇内离散度的比值来评估聚类质量, 值越大越好。

$$\text{CH} = \frac{\text{SSB}/(K-1)}{\text{SSW}/(n-K)}$$

其中：

K 是簇的数量, n 是样本总数, μ_k 是第 k 个簇的质心。

$\text{SSB} = \sum_{k=1}^K |C_k| |\mu_k - \mu|^2$: 簇间平方和 (Between-Cluster Sum of Squares)

$\text{SSW} = \sum_{k=1}^K \sum_{x_i \in C_k} |x_i - \mu_k|^2$: 簇内平方和 (Within-Cluster Sum of Squares)

CH 指数越大, 说明簇间差异越大、簇内越紧密, 聚类效果越好, 该指标对凸形簇效果较好, 但对任意形状簇可能失效。

③ Davies-Bouldin 指数 (DB Index)

DB 指数衡量簇内平均距离与簇间距离的比值, 值越小表示聚类质量越好。

$$\text{DB} = \frac{1}{K} \sum_{k=1}^K \max_{j \neq k} \left(\frac{\bar{d}_k + \bar{d}_j}{d(\mu_k, \mu_j)} \right)$$

其中：

$\bar{d}_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} |x_i - \mu_k|$: 簇 C_k 内样本到质心的平均距离。

$d(\mu_k, \mu_j) = |\mu_k - \mu_j|$: 簇 C_k 和 C_j 的质心距离。

DB 指数越小, 说明簇内越紧密、簇间越分离, 该指标适合球形簇, 对噪声和离群点敏感。

④ 调整兰德指数 (Adjusted Rand Index, ARI)

ARI 是对兰德指数 (Rand Index) 的调整版本, 考虑了随机聚类的影响, 取值范围为 $[-1, 1]$, 值越大表示聚类结果与真实标签越一致。

$$\text{ARI} = \frac{\text{RI} - \mathbb{E}[\text{RI}]}{\max(\text{RI}) - \mathbb{E}[\text{RI}]}$$

其中兰德指数定义为：

$$\text{RI} = \frac{TP + TN}{TP + TN + FP + FN}$$

调整后的 ARI 公式为：

$$ARI = \frac{\sum_{ij} \binom{n_{ij}}{2} [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}{\frac{1}{2} [\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}] - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}$$

其中：

n_{ij} ：真实标签为类别 i 、聚类结果为簇 j 的样本数。

$a_i = \sum_j n_{ij}$ ：真实标签为类别 i 的样本总数。

$b_j = \sum_i n_{ij}$ ：聚类结果为簇 j 的样本总数。

⑤归一化互信息（Normalized Mutual Information, NMI）

NMI 基于信息论中的互信息（Mutual Information）概念，衡量聚类结果与真实标签之间的信息共享程度，取值范围为[0,1]，值越大越好。

$$NMI = \frac{2 \times I(Y; C)}{H(Y) + H(C)}$$

其中：

$I(Y; C) = \sum_{i=1}^{K_Y} \sum_{j=1}^{K_C} P(i, j) \log \frac{P(i, j)}{P_Y(i)P_C(j)}$ ：互信息。

$H(Y) = -\sum_{i=1}^{K_Y} P_Y(i) \log P_Y(i)$ ：真实标签的熵。

$H(C) = -\sum_{j=1}^{K_C} P_C(j) \log P_C(j)$ ：聚类结果的熵。

$P(i, j) = \frac{|Y_i \cap C_j|}{n}$ ：联合概率。

$P_Y(i) = \frac{|Y_i|}{n}$, $P_C(j) = \frac{|C_j|}{n}$ ：边际概率。

2.4.2 模型训练流程

①Scikit-learn 库模型训练

基于 Scikit-learn 强大的机器学习生态，我们构建了涵盖划分式（K-Means）、层次化（Agglomerative Clustering）及基于密度（DBSCAN）的多元化聚类模型库。遵循标准化的无监督学习流程，我们首先将经 StandardScaler 归一化处理后的 Dry Bean 数据集输入模型，通过调用统一的 `.fit_predict()` 接口执行聚类任务，旨在让各算法从 16 维几何特征中自动发现干豆数据的内在分布结构与簇间差异；这一过程不仅实现了不同数学机理模型（如距离最小化、方差增量、密度连接）的并行训练，更为后续基于内部指标（轮廓系数、CH 指数）及外部指标（ARI、NMI）的性能对比与参数调优（如 K 值选择、Linkage 方式、eps 阈值）奠定了坚实的计算基础。

②手写模型训练

我们挑选了本实验的核心聚类算法——K-Means、层次聚类和 DBSCAN——进行手写实现（从零开始构建）。为了验证我们手动编写的模型（KMeansManual、AgglomerativeClusteringManual、DBSCANManual）的正确性，我们在标准化后的数据（或采样后的子集）上进行训练和推断，并将其聚类结果（ARI/NMI）及运行时间与 Scikit-

learn 库函数的表现进行严格对比。这确保手动实现的算法逻辑（如质心迭代更新、簇间距离计算、密度可达扩展）与标准库在原理上的一致性，同时通过对比运行效率（如朴素搜索和 KD 树优化），加深了对算法时间复杂度及收敛机制的理解。

2.5 结果可视化

我们首先进行了聚类结果的可视化，进行了不同模型手写与聚类的对比，并和真实场景进行对照，在此之后，我们还做了三种模型最优化参数下聚类结果的对比，结果如下所示：




图 3 K-means 结果可视化图




图 4 层次聚类结果可视化图




图 5 DBSCAN 聚类结果可视化图




图 6 最优参数总体聚类结果可视化图




图 7 K-means 聚类结果各类特征分布箱线图

2.6 分析和优化

2.6.1 模型结果分析

首先我们统计了不同 K 值 K-means 的各项指标：

表 3 不同 K 值 K-means 的各项指标统计表

K	轮廓系数	CH 指数	DB 指数	ARI	NMI
3	0.4404	8781.27	0.9013	0.2976	0.4856
4	0.3432	8355.43	0.9276	0.4422	0.6013
5	0.3572	8516.27	1.0256	0.5555	0.6921
6	0.3599	7978.45	0.9961	0.5400	0.6631
7	0.3088	7787.84	1.1021	0.6669	0.7124
8	0.3027	7359.92	1.1573	0.6969	0.7308
9	0.3029	7056.22	1.1646	0.6739	0.7214
10	0.2681	6702.08	1.2062	0.5633	0.6843

数据在宏观上可能表现为 3 个大簇（导致内部指标倾向 K=3），但在微观上确实包含 7 个具体的类别（导致外部指标在 K=7 附近表现较好）。

随后我们比较了调用 Scikit-learn 库训练的 K-means 模型与手写的进行比较（选取 K=7，真实类别数）：

表 4 调库与手写 K-means 的各项指标统计表

	迭代次数	运行时间	轮廓系数	CH 指数	DB 指数	ARI	NMI
调库	51	0.0435	0.2551	6966.20	1.2215	0.5782	0.6891
手写	21	0.1814	0.3469	6831.75	1.1528	0.5369	0.6574

手写实现虽然在几何指标上表现更优，但在还原真实标签上略逊于 sklearn 版本。

其次我们统计了不同连接方式的层次聚类的各项指标：

表 5 不同连接方式的层次聚类的各项指标统计表

连接方式	轮廓系数	CH 指数	DB 指数	ARI	NMI
ward	0.2886	7237.01	1.1266	0.6479	0.7306
complete	0.1606	2446.50	1.0970	0.1580	0.3622

续表 5

连接方式	轮廓系数	CH 指数	DB 指数	ARI	NMI
average	0.3757	861.61	0.8398	0.0346	0.1707
single	0.3634	12.71	0.3050	0.0001	0.0012

实验结果表明, Ward(最小方差法)是唯一能有效还原干豆真实类别的连接方式, 其 ARI (0.6479) 与 NMI (0.7306) 遥遥领先, 证明了该数据集倾向于紧凑的球状簇结构; 相比之下, Single(单链接)与 Average(平均链接)虽然展现出具有迷惑性的极优内部指标(如 Single 的 DB 指数最低), 但其 ARI 近乎为零, 导致将绝大多数样本归为一类, 未能实现有效聚类。

随后我们比较了调用 Scikit-learn 库训练的层次聚类模型与手写的进行比较(选取 K=7, 真实类别数):

表 6 调库与手写层次聚类的各项指标统计表

	运行时间	轮廓系数	CH 指数	DB 指数	ARI	NMI
调库	0.0040	0.4084	200.40	0.8195	0.4132	0.6424
手写	18.2054	0.4084	200.40	0.8195	0.4132	0.6424

除了运行效率, 二者性能极其相近。

最后我们统计了不同参数的 DBSCAN 的各项指标:

表 7 不同参数的 DBSCAN 的各项指标统计表

eps	min_samples	n_clusters	n_noise	轮廓系数	ARI
0.3	5	94	11822	-0.0375	0.0024
0.3	15	7	13142	-0.0278	0.0056
0.5	5	60	5935	-0.2858	0.1837
0.5	10	7	7452	0.0424	0.1342
0.7	5	29	2424	-0.3727	0.0666
0.7	15	7	4428	0.3142	0.2636
1.0	10	2	989	0.5733	0.0421
1.0	15	2	1189	0.5738	0.0443

实验结果揭示了 DBSCAN 对参数极高的敏感性及其在高维空间中的局限性: 在 eps=0.7 (min_samples=15) 时, 算法虽然捕捉到了真实的类别数量(7 个簇)并取得了最高的 ARI

(0.2636)，但代价是将超过 30%的数据误判为噪声（4428 个）；而当 $\text{eps}=1.0$ 时，虽然轮廓系数达到最优（0.5738）且噪声显著减少，但聚类数坍缩为 2，导致 ARI 骤降至 0.04，这说明算法为了追求几何上的紧密性而过度合并了不同品种的豆子，无法在去除噪声与保留类别细节之间取得平衡。

随后我们比较了调用 Scikit-learn 库训练的 DBSCAN 模型与手写的进行比较（簇数为 5）：

表 8 调库与手写 DBSCAN 的各项指标统计表

	运行时间	簇数	噪声点数	轮廓系数	ARI	NMI
调库	0.0105	5	397	0.4533	0.2373	0.0105
手写	3.6088	5	397	0.4533	0.2373	0.0105

除了运行效率，二者性能极其相近。

2.6.2 自定义聚类视角

为了探索除原始生物分类标签之外的数据内在结构，实验基于物理意义将特征划分为两个子集，设计了两种不同的聚类视角：

①视角一：按大小形态聚类（Size/Morphology）

选取与豆子物理尺寸直接相关的特征，如 Area（面积）、Perimeter（周长）、MajorAxisLength（长轴长）等。忽略形状细节（如是否圆润），仅根据豆子的体积大小和整体轮廓进行分组。

最终聚类出 6 个簇。适用于工业生产中需要按尺寸分级筛选（Size Grading）的场景，可能会将不同品种但大小相近的豆子归为一类。

②视角二：按形状因子聚类（Shape Factors）

选取描述几何形状的无量纲特征，如 roundness（圆度）、Compactness（紧致度）、ShapeFactor1-4 等。忽略颗粒大小差异，仅关注豆子的几何形状（如圆形和细长形）。

最终聚类出 8 个簇。适用于对豆子外观形态有严格要求的质量控制场景，能有效区分圆豆与长豆。

表 9 不同视角的 K-means 聚类的各项指标统计表

聚类视角	特征数	轮廓系数	ARI	NMI
全特征	16	0.3088	0.6670	0.7124
大小形态	8	0.4196	0.4195	0.5538
形状因子	8	0.3377	0.5526	0.6267

全特征聚类（使用所有 16 个特征）在 ARI 和 NMI 指标上最高，说明其与原始的生物学分类（7 类）最吻合。自定义视角虽然在还原真实标签的指标上略低，但揭示了数据在不同物理维度上的自然分布规律。这证明了特征选择能显著改变聚类结果，使其适应不同的实际应用需求（如分大小与分形状）。




图 8 不同聚类视角聚类结果可视化

3 总结

本项目以 Dry Bean 数据集为核心，经过严格的数据清洗、标准化及 PCA 降维预处理，系统评估了 K-Means、层次聚类（Agglomerative）和 DBSCAN 三种经典算法在农产品无监督分类中的性能表现。通过对比 Scikit-learn 库函数与手写实现，并结合内部（轮廓系数、CH、DB）与外部（ARI、NMI）评价指标，实验发现 K-Means（K=7）与采用 Ward 连接的层次聚类在还原真实类别分布上效果最佳，而 DBSCAN 则受限于参数敏感性与高维空间特性；此外，实验引入“大小形态”与“形状因子”2 个自定义聚类视角，有效揭示了不同特征子集对聚类模式的主导作用，证明了聚类分析在农产品多维度智能分选与质量控制中的实际应用价值。

4 组员及任务分配情况

：数据处理，模型优化，模型对比和可视化，实验报告撰写。

许思源：数据处理，利用 scikit-learn 进行模型搭建，可视化。

汪君哲：数据处理，手写实现聚类模型，结果分析，可视化。

参考文献

- [1] Koklu M, Ozkan I A. Multiclass classification of dry beans using computer vision and machine learning techniques[J]. Computers and Electronics in Agriculture, 2020, 174: 105507.
- [2] McQueen J B. Some methods of classification and analysis of multivariate observations[C]//Proc. of 5th Berkeley Symposium on Math. Stat. and Prob. 1967: 281-297.
- [3] Rokach L, Maimon O. Clustering methods Data mining and knowledge discovery handbook (pp. 321–352)[J]. 2005.
- [4] A density-based algorithm for discovering clusters in large spatial databases with noise[C]//kdd. 1996, 96(34): 226-231.