

多元分析课后作业

1.

10.1 表 10.1 是 1999 年中国省、自治区的城市规模结构特征的一些数据,试通过聚类分析将这些省、自治区进行分类。

表 10.1 城市规模结构特征数据

省、自治区	城市规模 /万人	城市首位度	城市指数	基尼系数	城市规模中位 值/万人
京津冀	699.70	1.4371	0.9364	0.7804	10.880
山西	179.46	1.8982	1.0006	0.5870	11.780
内蒙古	111.13	1.4180	0.6772	0.5158	17.775
辽宁	389.60	1.9182	0.8541	0.5762	26.320
吉林	211.34	1.7880	1.0798	0.4569	19.705
黑龙江	259.00	2.3059	0.3417	0.5076	23.480
苏沪	923.19	3.7350	2.0572	0.6208	22.160
浙江	139.29	1.8712	0.8858	0.4536	12.670
安徽	102.78	1.2333	0.5326	0.3798	27.375
福建	108.50	1.7291	0.9325	0.4687	11.120
江西	129.20	3.2454	1.1935	0.4519	17.080
山东	173.35	1.0018	0.4296	0.4503	21.215
河南	151.54	1.4927	0.6775	0.4738	13.940
湖北	434.46	7.1328	2.4413	0.5282	19.190
湖南	139.29	2.3501	0.8360	0.4890	14.250
广东	336.54	3.5407	1.3863	0.4020	22.195
广西	96.12	1.2288	0.6382	0.5000	14.340
海南	45.43	2.1915	0.8648	0.4136	8.730
川渝	365.01	1.6801	1.1486	0.5720	18.615
云南	146.00	6.6333	2.3785	0.5359	12.250
贵州	136.22	2.8279	1.2918	0.5984	10.470
西藏	11.79	4.1514	1.1798	0.6118	7.315
陕西	244.04	5.1194	1.9682	0.6287	17.800
甘肃	145.49	4.7515	1.9366	0.5806	11.650
青海	61.36	8.2695	0.8598	0.8098	7.420
宁夏	47.60	1.5078	0.9587	0.4843	9.730
新疆	128.67	3.8535	1.6216	0.4901	14.470

(1)变量定义

设有 n 个省（自治区）样本，每个样本具有 p 个城市结构特征，原始数据矩阵为：

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & & x_{2p} \\ \vdots & & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$$

(2) 标准化处理 (Z-score 标准化)

为了消除不同量纲影响，采用 Z-score 标准化。

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

其中， $\mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$ 为特征均值， $\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2}$ 为标准差。

标准化后形成新矩阵： $\mathbf{Z} = [z_{ij}] \in \mathbb{R}^{n \times p}$ 。

(3) 聚类分析

面对这个问题，我有两个解决思路，第一个是采用层次聚类分析 (Hierarchical Clustering)，第二个是采用 K-means 聚类分析。

① 层次聚类分析 (Hierarchical Clustering)

第一，计算样本之间的欧氏距离矩阵 $D \in \mathbb{R}^{n \times n}$ 。

$$d_{ij} = \|\mathbf{z}_i - \mathbf{z}_j\|^2 = \sqrt{\sum_{k=1}^p (z_{ik} - z_{jk})^2}$$

第二，采用单连接法 (Single Linkage) 进行聚类链接，两个簇之间的距离定义为：

$$\text{dist}(C_a, C_b) = \min_{\mathbf{z}_i \in C_a, \mathbf{z}_j \in C_b} \|\mathbf{z}_i - \mathbf{z}_j\|^2$$

通过递归合并距离最近的两个簇，构造聚类树。

第三，用轮廓系数法确定最优聚类数。设尝试聚类数为 $k \in \{2, 3, \dots, K\}$ ，通过轮廓系数 (Silhouette Coefficient) 选取最优 k 。

对于每个样本 i ，样本的轮廓系数为：

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1]$$

其中， $a(i)$ 是样本 i 与同簇中其他样本的平均距离， $b(i)$ 是样本 i 与最近邻簇中所有样本的平均距离。

所有样本的平均轮廓系数为：

$$\bar{s}(k) = \frac{1}{n} \sum_{i=1}^n s(i)$$

最终选择最优聚类数：

$$k^* = \arg \max_k \bar{s}(k)$$

第四，最终聚类划分。根据树状图切割成 k^* 个簇，得到每个样本的聚类标签：

$$\ell_i \in \{1, 2, \dots, k^*\}$$

聚类结果为：第 i 个省份被分到第 ℓ_i 类中。

②K-means 聚类分析

第一，K-means 聚类目标是将标准化样本 $\mathbf{z}_i \in \mathbb{R}^p$ 分成 k 个簇 $\{C_1, C_2, \dots, C_k\}$ ，，最小化总平方误差：

$$\text{SSE}(k) = \sum_{j=1}^k \sum_{\mathbf{z}_i \in C_j} \|\mathbf{z}_i - \boldsymbol{\mu}_j\|^2$$

其中， $\boldsymbol{\mu}_j = \frac{1}{|C_j|} \sum_{\mathbf{z}_i \in C_j} \mathbf{z}_i$ 是第 j 个簇的中心（均值向量），最终返回每个样本的聚类标签：

$$\ell_i \in \{1, 2, \dots, k\}$$

第二，用肘部法确定最优聚类数。构造 k 的总平方误差（SSE）一阶差分序列（即相邻两个 SSE 值的变化量）：

$$\Delta_1(k) = \text{SSE}(k) - \text{SSE}(k+1)$$

再计算二阶差分（斜率变化率）：

$$\Delta_2(k) = \Delta_1(k) - \Delta_1(k+1) = \text{SSE}(k) - 2 \cdot \text{SSE}(k+1) + \text{SSE}(k+2)$$

选取使最大的 k ，作为最优聚类数：

$$k^* = \arg \max_k |\Delta_2(k)|$$

最终使用 $k = k^* + 1$ 或 $k = k^* + 2$ （根据差分偏移）作为最终聚类数。

(4)求解与输出

调用 `disp` 函数输出聚类结果，输出每个类别中对应的省份列表，并用 PCA 投影到二维平面。

(5)代码实现和输出

①层次聚类分析（Hierarchical Clustering）




```
clc; clear; close all;
% 读取数据
filename = 'hw6_1.txt';
opts = detectImportOptions(filename, 'Delimiter', '\t'); % 假设用制表符分隔
T = readtable(filename, opts);
% 提取变量
province = T(:, 1); % 第一列是省份名称
X = table2array(T(:, 2:end)); % 数值部分
X_norm = zscore(X); % 标准化数值数据
% 层次聚类
z = linkage(X_norm, 'single'); % 使用单连接法
% 绘制树状图
figure;
dendrogram(z, 0, 'Labels', province, 'Orientation', 'left'); % 0 表示显示所有节点
title('层次聚类树状图');
% 自动选择最优 k（基于轮廓系数）
max_k = 10;
silhouette_avg = zeros(1, max_k);
for k = 1:max_k
    idx = cluster(z, 'maxclust', k); % 切割聚类树
    sil = silhouette(X_norm, idx, 'euclidean'); % 计算轮廓系数
    silhouette_avg(k) = mean(sil); % 平均轮廓系数
end
[~, optimal_k] = max(silhouette_avg);
fprintf('基于轮廓系数的最优 k: %d\n', optimal_k);
% 绘制轮廓系数图
figure;
plot(1:max_k, silhouette_avg, '-o');
xlabel('聚类数 k');
ylabel('平均轮廓系数');
title('轮廓系数确定最优聚类数');
% 使用最优 k 执行聚类并输出结果
idx = cluster(z, 'maxclust', optimal_k);
for i = 1:optimal_k
    fprintf('聚类 %d:\n', i);
    disp(province(idx == i)); % 显示每个簇的标签
end
% PCA 可视化
[coeff, score] = pca(X_norm);
figure;
```

```
gscatter(score(:,1), score(:,2), idx);
xlabel('PCA 1'); ylabel('PCA 2');
title('城市结构特征聚类可视化');
text(score(:,1)+0.02, score(:,2), province, 'FontSize', 8);
```

基于轮廓系数的最优 k: 4

- 聚类 1:
{ '青海' }
- 聚类 2:
{ '山西' }
{ '内蒙古' }
{ '辽宁' }
{ '吉林' }
{ '黑龙江' }
{ '浙江' }
{ '安徽' }
{ '福建' }
{ '江西' }
{ '山东' }
{ '河南' }
{ '湖北' }
{ '湖南' }
{ '广东' }
{ '广西' }
{ '海南' }
{ '川渝' }
{ '云南' }
{ '贵州' }
{ '西藏' }
{ '陕西' }
{ '甘肃' }
{ '宁夏' }
{ '新疆' }

- 聚类 3:
{ '京津冀' }
- 聚类 4:
{ '苏沪' }



②K-means 聚类分析

```
filename = 'hw6_1.txt';
% 假设文件是以空格或制表符分隔
opts = detectImportOptions(filename, 'Delimiter', '\t'); % 或 ' ' 空格
T = readtable(filename, opts);
% 提取变量
province = T{:, 1}; % 第一列是省份名称
X = table2array(T(:, 2:end)); % 数值部分
X_norm = zscore(X);
sumd_all = zeros(1, 10);
for k = 1:10
    [~, ~, sumd] = kmeans(X_norm, k, 'Replicates', 10);
    sumd_all(k) = sum(sumd);
end
figure;
plot(1:10, sumd_all, '-o');
xlabel('聚类数 k');
ylabel('总距离 (SSE)');
title('肘部法确定最优聚类数');
% 选择 k
diff1 = diff(sumd_all); % 一阶差分 (斜率)
diff2 = diff(diff1); % 二阶差分 (斜率的变化)
[~, max_change_idx] = max(abs(diff2)); % 找到二阶差分绝对值最大的点
optimal_k = max_change_idx + 2; % 加 2 因为 diff2 比 sumd_all 短两个元素
fprintf('选择的最优 k: %d\n', optimal_k);
[idx, C] = kmeans(X_norm, optimal_k, 'Replicates', 10);
for i = 1:optimal_k
    fprintf('聚类 %d:\n', i);
    disp(province(idx == i));
end
[coeff, score] = pca(X_norm);
figure;
gscatter(score(:,1), score(:,2), idx);
xlabel('PCA 1'); ylabel('PCA 2');
title('城市结构特征聚类可视化');
text(score(:,1)+0.02, score(:,2), province, 'FontSize', 8);
```

聚类 1:

聚类 1:



- { '山西' }
- { '内蒙古' }
- { '辽宁' }
- { '吉林' }
- { '黑龙江' }
- { '浙江' }
- { '安徽' }
- { '福建' }
- { '江西' }
- { '山东' }
- { '河南' }
- { '湖南' }
- { '广东' }
- { '广西' }
- { '海南' }
- { '川渝' }
- { '宁夏' }

聚类 2:

```
{ '京津冀' }
{ '苏沪' }
```

聚类 3:

```
{ '湖北' }
{ '云南' }
{ '贵州' }
{ '西藏' }
{ '陕西' }
{ '甘肃' }
{ '青海' }
{ '新疆' }
```



2.

10.2 表 10.54 是我国 1984—2000 年宏观投资的一些数据,试利用主成分分析对投资效益进行分析和排序。

表 10.54 1984—2000 年宏观投资效益主要指标

年份	投资效果系数 (无时滞)	投资效果系数 (时滞一年)	全社会固定资产 交付使用率	建设项目 投产率	基建房屋 竣工率
1984	0.71	0.49	0.41	0.51	0.46
1985	0.40	0.49	0.44	0.57	0.50
1986	0.55	0.56	0.48	0.53	0.49
1987	0.62	0.93	0.38	0.53	0.47
1988	0.45	0.42	0.41	0.54	0.47
1989	0.36	0.37	0.46	0.54	0.48
1990	0.55	0.68	0.42	0.54	0.46
1991	0.62	0.90	0.38	0.56	0.46
1992	0.61	0.99	0.33	0.57	0.43
1993	0.71	0.93	0.35	0.66	0.44
1994	0.59	0.69	0.36	0.57	0.48
1995	0.41	0.47	0.40	0.54	0.48
1996	0.26	0.29	0.43	0.57	0.48
1997	0.14	0.16	0.43	0.55	0.47
1998	0.12	0.13	0.45	0.59	0.54
1999	0.22	0.25	0.44	0.58	0.52
2000	0.71	0.49	0.41	0.51	0.46

(1)变量定义

设有 n 个省(自治区)样本,每个样本具有 p 个城市结构特征,原始数据矩阵为:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$$

(2)标准化处理 (Z-score 标准化)

为了消除不同量纲影响,采用 Z-score 标准化。

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

其中, $\mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$ 为特征均值, $\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2}$ 为标准差。

标准化后形成新矩阵: $\mathbf{Z} = [z_{ij}] \in \mathbb{R}^{n \times p}$ 。

(3)相关系数矩阵与特征值分解

利用标准化矩阵 $\mathbf{Z}$ 计算相关系数矩阵:

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z} = \frac{1}{n-1} \sum_{i=1}^n z_{ij} z_{ik}$$

这是一个对称正定矩阵, 用于反映各指标间的线性相关程度。

(4)特征值与特征向量分解

对 $\mathbf{R}$ 进行特征值分解:

$$\mathbf{R} \mathbf{a}_i = \lambda_i \mathbf{a}_i, i = 1, 2, \dots, p$$

其中, λ_i 是第 i 个特征值(表示该主成分的方差), $\mathbf{a}_i \in \mathbb{R}^p$ 是对应的特征向量, 记 $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p]$ 为对应的单位正交特征向量矩阵。

按特征值从大到小排序: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$, 记 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$ 。则:

$$\mathbf{R} = \mathbf{A} \mathbf{\Lambda} \mathbf{A}^T$$

(5)主成分构造及解释

将标准化数据投影到特征向量上, 得第 j 个主成分:

$$y_j = \mathbf{Z} \cdot \mathbf{a}_j = a_{1j}z_1 + a_{2j}z_2 + \dots + a_{pj}z_p \Leftrightarrow y_j^{(i)} = \sum_{k=1}^p a_{kj} z_{ik}$$

表示第 i 年在第 j 主成分上的得分。主成分之间相互正交, 且方差为 $\text{Var}(y_j) = \lambda_j$ 。

(6)贡献率计算

每个主成分的贡献率表示它所解释的原始数据方差的比例:

$$\eta_j = \frac{\lambda_j}{\sum_{k=1}^p \lambda_k}$$

累计贡献率: $\gamma_k = \sum_{j=1}^k \eta_j$, 我们可以根据累计贡献率选择前 k 个主成分, 用于构造综合评价指标。

(7)主成分表达式

对每一年(每行)数据:

$$y_{ij} = \mathbf{a}_j^T \mathbf{z}_i = a_{1j}z_{1i} + a_{2j}z_{2i} + \cdots + a_{pj}z_{pi}$$

主成分得分矩阵表示为：

$$\mathbf{Y} = \mathbf{Z} \cdot \mathbf{A}_k$$

其中 $\mathbf{A}_k$ 是前 k 个主成分的特征向量组成矩阵。若选取前 3 个主成分，则每一年的得分为：

$$\mathbf{Y} = \mathbf{Z} \cdot \mathbf{A}_3 = \begin{bmatrix} y_1^{(1)} & y_2^{(1)} & y_3^{(1)} \\ \vdots & \vdots & \vdots \\ y_1^{(n)} & y_2^{(n)} & y_3^{(n)} \end{bmatrix}$$

(8)综合得分计算与排序

我们可以根据两种方式构造综合得分：

①方式一：全部主成分加权

$$F_i = \sum_{j=1}^p \eta_j \cdot y_{ij}$$

即将每个主成分得分乘以其方差贡献率，再求和。

②方式二：前三主成分加权

$$w_j = \frac{\eta_j}{\gamma_3}, F_i^{(3)} = \sum_{j=1}^3 w_j \cdot y_{ij}$$

此方式关注主要成分，常用于简化模型分析。

最后，将 F_i 从大到小排序，即得各年份的投资效益排名。

(9)求解与输出

调用 `disp` 函数输出排序结果，利用柱状图展示：各年份的第 1 主成分得分；所有主成分加权得分；前 3 主成分加权得分。

(10)代码实现和输出

```
clc; clear; close all;
% 1. 读取数据
T = readtable('hw6_2.txt');
year = T{:,1};
X = T{:,2:end};
```

```

% 2. 数据标准化
Z = zscore(X);
% ===== 特征值 + 特征向量分析 =====
R = corrcoef(Z); % 相关系数矩阵
[eigVec, eigVal_matrix] = eig(R); % 特征值分解
eigVal = diag(eigVal_matrix); % 提取特征值
[eigVal_sorted, idx] = sort(eigVal, 'descend');
eigVec_sorted = eigVec(:, idx); % 排序后的特征向量（按特征值顺序）
% 计算贡献率
total = sum(eigVal_sorted);
contribution_rate = eigVal_sorted / total;
cumulative_rate = cumsum(contribution_rate);
% 输出前 5 个特征值及贡献率
fprintf('前 5 个特征值及其贡献率: \n');
fprintf('-----\n');
fprintf('主成分\t特征值\t\t贡献率(%%)\t累计贡献率(%%)\n');
for i = 1:5
    fprintf('PC%d\t%.4f\t%.2f%%\t%.2f%%\n', ...
        i, eigVal_sorted(i), contribution_rate(i)*100,
        cumulative_rate(i)*100);
end
fprintf('-----\n\n');
% ===== 输出前 3 个主成分对应的特征向量 =====
fprintf('前 3 个主成分的特征向量（对应标准化变量系数）: \n');
for i = 1:3
    fprintf('y%d = ', i);
    for j = 1:size(eigVec_sorted,1)
        coef = eigVec_sorted(j,i);
        if coef >= 0 && j > 1
            fprintf(' + ');
        end
        fprintf('%.4f * x%d ', coef, j);
    end
    fprintf('\n');
end
fprintf('\n');
% ===== 主成分分析 =====
[coeff, score, latent, ~, explained] = pca(Z); % explained 为每个主成分贡献率(%)
% ===== 综合得分计算 =====
explained_ratio = explained / 100;
composite_score = score * explained_ratio;
% ===== 综合得分排序 =====
[sorted_score, idx] = sort(composite_score, 'descend');

```

```

sorted_year = year(idx);
% 输出结果
disp('年份排序结果（按投资效益）：');
disp(table(sorted_year, sorted_score));
% ===== 全部主成分综合评价模型 =====
figure;
bar(score(:,1), 'FaceColor', [0.2 0.6 0.8]);
xticks(1:length(year)); xticklabels(string(year)); xtickangle(45);
ylabel('第一主成分得分');
title('第一主成分得分（代表主要投资效益）'); grid on;
figure;
bar(composite_score, 'FaceColor', [0.4 0.7 0.2]);
xticks(1:length(year)); xticklabels(string(year)); xtickangle(45);
ylabel('综合得分');
title('各年份投资效益综合得分（主成分加权）'); grid on;
% ===== 前 3 主成分综合评价模型 =====
score_3 = score(:,1:3); % 取前 3 个主成分得分
weight_3 = explained(1:3); % 前 3 主成分贡献率（百分比）
weight_3 = weight_3 / sum(weight_3); % 转为归一化权重
score_3_weighted = score_3 * weight_3; % 前 3 主成分加权得分
% 排序并输出
[sorted_score3, idx3] = sort(score_3_weighted, 'descend');
sorted_year3 = year(idx3);
fprintf('\n 根据前三主成分构建的综合评价模型结果（按得分降序排列）：\n');
disp(table(sorted_year3, sorted_score3));
% 可视化
figure;
bar(score_3_weighted, 'FaceColor', [0.7 0.4 0.4]);
xticks(1:length(year)); xticklabels(string(year)); xtickangle(45);
ylabel('前 3 主成分加权得分');
title('投资效益综合评价（基于前 3 个主成分）'); grid on;

```

前5个特征值及其贡献率：

主成分	特征值	贡献率 (%)	累计贡献率 (%)
PC1	3.1343	62.69%	62.69%
PC2	1.1683	23.37%	86.05%
PC3	0.3502	7.00%	93.06%
PC4	0.2258	4.52%	97.57%
PC5	0.1213	2.43%	100.00%

前3个主成分的特征向量（对应标准化变量系数）：
 $y_1 = -0.4905 * x_1 - 0.5254 * x_2 + 0.4871 * x_3 - 0.0671 * x_4 + 0.4916 * x_5$
 $y_2 = 0.2934 * x_1 - 0.0490 * x_2 + 0.2812 * x_3 - 0.8981 * x_4 - 0.1606 * x_5$
 $y_3 = -0.5109 * x_1 - 0.4337 * x_2 - 0.3714 * x_3 - 0.1477 * x_4 - 0.6255 * x_5$

年份排序结果（按投资效益）：		根据前三主成分构建的综合评价模型结果：	
sorted_year	sorted_score	sorted_year3	sorted_score3
1993	2.4797	1993	2.6289
1992	1.9719	1992	2.1243
1991	1.1133	1991	1.1953
1987	0.82502	1994	0.92457
1994	0.81694	1987	0.90865
1990	0.24857	1990	0.24264
2000	0.041053	2000	0.057061
1984	0.041053	1984	0.057061
1988	-0.27172	1995	-0.27232
1995	-0.27556	1988	-0.28606
1985	-0.52239	1985	-0.56864
1996	-0.72575	1996	-0.79574
1986	-0.74189	1986	-0.83698
1989	-0.94057	1989	-1.044
1997	-1.132	1997	-1.2332
1999	-1.217	1999	-1.2911
1998	-1.7107	1998	-1.8105

