面向轨迹修复的数学建模

摘 要

针对轨迹修复问题，本研究提出了一种基于随机森林回归的混合预测方法，结合传统插值技术，实现 GPS 轨迹数据中缺失点的坐标补全。通过 Z-score 和 IQR 方法清洗异常值，Savitzky-Golay 滤波平滑轨迹，并设计包含空间、时间和动态信息的 12 维特征矩阵，利用 Haversine 公式确保地理准确性。随机森林模型有效捕捉非线性关系，混合预测机制增强鲁棒性。采用 MSE、RMSE、MAE、Frechet 距离和 DTW 等多维指标评估性能，平均 MSE 为 0.002315，Frechet 距离为 0.068813，修复轨迹拟合较好。可视化结果进一步验证了模型效果。研究为智慧交通和位置服务提供了解决方案，未来可通过引入路网信息和深度学习模型进一步优化。

关键词：轨迹修复，随机森林回归，时空数据特征，误差评估

目 录

1 问题重述 1
1.1 问题背景 1
1.2 问题要求 1
2 问题分析与模型设想 2
2.1 问题分析 2
2.1.1 数据处理与分析 2
2.1.2 模型构建与方法选择 2
2.1.3 缺失点预测与轨迹修复 2
2.1.4 评估与结果分析 2
2.2 模型设想 3
2.2.1 数据预处理阶段 3
2.2.2 模型训练阶段 3
2.2.3 修复预测阶段 4
2.2.4 评估输出阶段 5
2.2.5 模型架构 5
3 模型假设与约定 7
3.1 数据分布假设 7
3.2 时空连续性假设 7
3.3 模型特征有效性假设 7
4 数据预处理 8
4.1 数据解析与缺失值处理 8
4.1.1 输入数据格式 8
4.1.2 解析流程 8
4.2 异常值检测与清洗 8
4.2.1 坐标异常值检测（Z-score 方法） 8
4.2.2 速度异常检测（IQR 方法） 9
4.3 轨迹平滑处理——Savitzky-Golay 滤波器 9
4.4 时间戳与空间坐标插值 10

4.4.1 时间戳插值 10
4.4.2 空间坐标插值 10
5 模型建立与解决 11
5.1 特征工程 11
5.1.1 特征生成过程 11
5.1.2 特征的作用与数学解释 13
5.1.3 特征工程的优点 13
5.2 模型建立 14
5.3 模型训练 15
5.3.1 训练数据的生成和特征标准化 15
5.3.2 训练数据的划分 16
5.3.3 模型训练过程 16
5.3.4 模型训练过程的优势 16
6 模型检验与评估 18
6.1 模型检验与评估概述 18
6.2 模型检验与评估详细描述 18
6.2.1 均方误差（MSE） 19
6.2.2 均方根误差（RMSE） 19
6.2.3 平均绝对误差（MAE） 20
6.2.4 Frechet 距离 20
6.2.5 动态时间规整（DTW） 21
6.3 模型轨迹预测可视化展示 21
7 总 结 24
参考文献 25

1 问题重述

1.1 问题背景

在智慧交通、城市物流调度和位置服务（Location-Based Services, LBS）等领域中，轨迹数据作为刻画车辆或用户空间移动行为的重要信息载体，已成为交通管理与时空行为分析中的关键数据来源。通过对轨迹数据的深入挖掘，可以实现交通流量监控、路径优化、用户行为建模等多种智能应用。然而，由于 GPS 信号受环境遮挡、设备故障或网络中断等因素影响，轨迹数据中常常存在噪声、异常值或局部缺失。这些缺失不仅降低了轨迹数据的完整性和可信度，也对后续的建模与决策造成了较大干扰。

为了解决轨迹数据中的缺失问题，近年来学术界与工业界提出了多种修复策略，涵盖插值算法、统计回归模型及深度学习方法等。这些方法试图在已知轨迹点的基础上，结合时间、空间、速度等特征信息，预测出缺失时段中目标的可能位置。其中，不仅需要考虑轨迹的时序连续性，还需捕捉运动模式和可能的空间路径，部分方法还引入了路网匹配等外部辅助信息以提升修复精度。

1.2 问题要求

本建模任务聚焦于轨迹修复问题。我们将利用一组包含时间戳和 GPS 坐标的训练数据，探索适合轨迹补全的数学模型，并在测试集中对被掩码（mask）的位置进行坐标预测。任务要求涵盖数据预处理、轨迹特征提取、模型构建、误差评估与结果可视化，考验建模者对时空数据的理解、算法设计与评估能力。目标是在尽可能接近真实轨迹的前提下，恢复缺失坐标，为后续智能决策提供可靠支持。

2 问题分析与模型设想

2.1 问题分析

本题围绕“轨迹修复”任务展开，旨在通过建模手段对缺失的 GPS 轨迹坐标进行合理预测与补全。具体而言，任务分为以下几个核心环节：

2.1.1 数据处理与分析

数据清洗：对训练集中轨迹数据进行初步处理，包括去除异常点、平滑噪声等，以提高数据质量。

利用可视化分析：通过时间轴、地理分布等方式对轨迹进行可视化，帮助建模者理解目标的运动规律和时空特性。

特征提取：基于原始经纬度数据，尝试构造速度、加速度、方向角、时间间隔等辅助特征，为后续模型提供更丰富的输入信息。

2.1.2 模型构建与方法选择

方法选择：可以采用传统插值方法（如线性插值、样条插值等）、统计方法（如多元回归、树模型），或深度学习方法（如 RNN、LSTM、时空图卷积等）对轨迹进行建模与预测。

训练测试划分：需自行将提供的训练集划分为子训练集与验证集，用于模型训练与性能验证。

2.1.3 缺失点预测与轨迹修复

对测试集中存在 mask 的轨迹，使用训练得到的模型进行位置坐标的预测与补全，输出修复后的完整轨迹序列。

2.1.4 评估与结果分析

误差评估指标：使用多种误差评估指标（如 MSE、MAE、RMSE、Frechet 距离、DTW 等）对修复结果与真实轨迹进行比较，量化模型预测精度。

可视化展示：绘制原始轨迹、修复轨迹及误差分布图，直观反映模型修复效果。

精度分析：如引入路网匹配信息，应同时提供使用与不使用路网信息的对比结果。

2.2 模型设想

2.2.1 数据预处理阶段

- 异常值清洗：采用 Z-score 方法过滤坐标异常点
- 速度检测：通过 IQR 方法识别速度突变点
- 轨迹平滑：Savitzky-Golay 滤波器保留运动趋势
- 时间插值：为掩码点分配合理时间戳

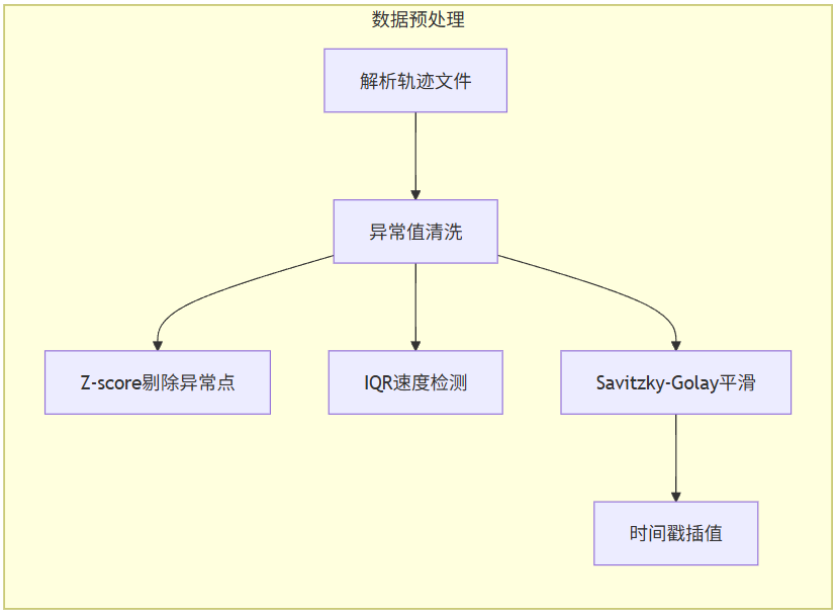

图 1 数据预处理流程图

2.2.2 模型训练阶段

- 上下文采样：提取掩码点前后有效点构建样本
- 特征构建：包含空间关系(prev_lon, prev_lat, next_lon, next_lat)、时间占比(rel_time)、总时间差(total_delta)
- 模型选择：随机森林处理非线性关系，验证集评估防止过拟合

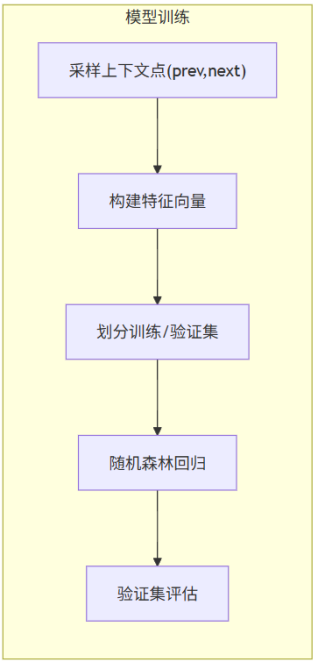

图 2 模型训练流程图

2.2.3 修复预测阶段

- 双保险策略：优先使用模型预测，失败时切换线性插值
- 空间插值：前后点坐标取平均作为后备方案
- 时间插值：基于时间比例分配坐标

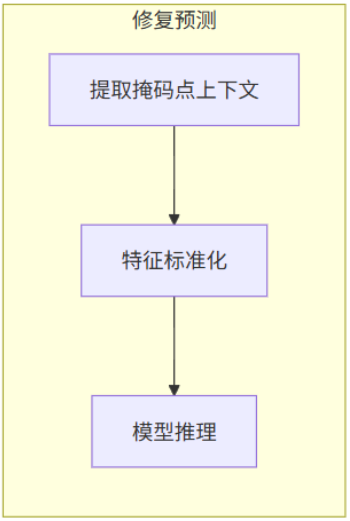

图 3 修复预测流程图

2.2.4 评估输出阶段

- 双维度评估：点级精度(MSE) + 轨迹相似性(Frechet)
- 可视化对比：原始轨迹/修复轨迹叠加显示
- 错误分析：统计不同缺失长度下的修复效果

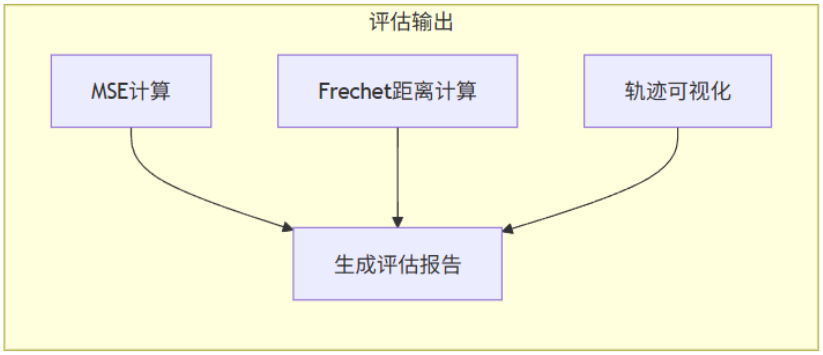

图 4 评估输出流程图

2.2.5 模型架构

- **混合预测机制**

将机器学习模型与传统插值方法结合，在保证精度的同时增强鲁棒性。

- **时空联合特征**

通过 rel_time 特征编码时间占比，捕捉加速/减速运动模式。

- **物理约束设计**

基于速度阈值过滤不合理轨迹点，保证运动连续性。

- **多维评估体系**

同时关注局部坐标精度与整体轨迹形态的保持能力。

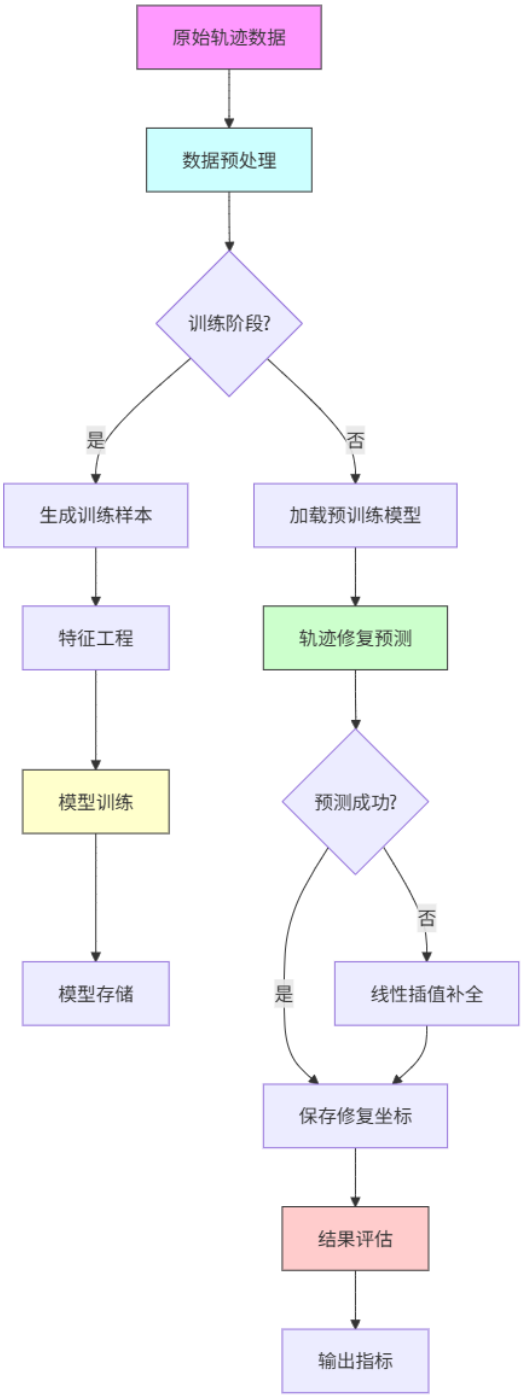
原始轨迹数据
数据预处理
训练阶段?
是
否
生成训练样本
加载预训练模型
特征工程
轨迹修复预测
模型训练
预测成功?
否
是
模型存储
线性插值补全
保存修复坐标
结果评估
输出指标

图 5 模型架构图

3 模型假设与约定

3.1 数据分布假设

● 正态分布假设

使用 Z-score 方法检测经纬度异常值时，默认数据近似服从正态分布。假设实际数据不存在显著偏态或多峰分布（如车辆常在某几个区域聚集。

● 速度对称性假设

通过 IQR 方法检测速度异常时，假设速度分布对称。忽略实际场景中，可能存在的车辆加速与减速模式不对称，导致阈值设定偏差。

3.2 时空连续性假设

● 时间线性插值有效性

为掩码点分配时间戳时，假设时间在前后有效点之间线性变化，可通过前后有效点的时间线性插值近似。忽略车辆实际行驶中存在变加速，导致线性插值的时间与真实时间产生的偏差。

$$t_{mask} = t_{prev} + \alpha(t_{next} - t_{prev})$$

其中 α 为掩码点在前、后点间的相对位置比例。

● 局部轨迹平滑性

使用 Savitzky-Golay 滤波器平滑轨迹时，假设局部轨迹可用低阶多项式拟合。忽略急转弯或复杂路网区域，过度平滑导致的细节丢失。

3.3 模型特征有效性假设

● **上下文特征充分性**

模型输入包含前后点的坐标和时间差，以及速度和方向等特征，隐含假设这些特征足以表征运动规律。忽略更高阶因素（如加速度）对轨迹的影响。

● **独立同分布假设**

随机森林模型默认样本独立，忽略轨迹数据的时序依赖性，相邻样本存在自相关。

4 数据预处理

轨迹数据的预处理是确保后续建模与修复效果的关键步骤。本程序针对原始轨迹数据的特点，设计了包含数据解析、异常值清洗、轨迹平滑及时间戳插值等多阶段预处理流程。以下详细介绍各环节的处理方法与数学原理。

4.1 数据解析与缺失值处理

4.1.1 输入数据格式

```
2023-01-01 08:00:00,116.3975,39.9087
MASK
2023-01-01 08:00:30,116.3982,39.9091
```

每条轨迹以文本文件存储，每行包含时间戳、经度、纬度或标记为 MASK 的缺失点。示例格式如下：

4.1.2 解析流程

行解析：逐行读取文件，若行为 MASK，则记录为掩码点（mask=True，坐标设为 NaN）；否则解析时间戳、经度、纬度。

时间戳分配：对掩码点的时间戳进行线性插值：

设掩码点位于索引i，其前后有效点索引为i_{prev}和i_{next}，对应时间戳为t_{prev}和t_{next}。插值时间戳为：

$$t_i = t_{\text{prev}} + \frac{i - i_{\text{prev}}}{i_{\text{next}} - i_{\text{prev}}} \cdot \left(t_{\text{next}} - t_{\text{prev}}\right)$$

若掩码点位于轨迹首尾，则采用最近邻时间戳。

4.2 异常值检测与清洗

4.2.1 坐标异常值检测（Z-score 方法）

- 计算有效点的均值和标准差

仅对非掩码点（mask=False）计算经度、纬度的均值和标准差（纬度计算同理）：

$$\mu_{lon} = \frac{1}{N}\sum_{i=1}^{N} lon_i\,,$$

$$\sigma_{lon} = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(-\mu_{lon})^2}$$

● 异常点判定

对每个有效点计算 Z-score，若超出阈值则标记为异常，若 $Z_{lon}>Z_{thres}$ 或 $Z_{lat}>Z_{thres}$，则将该点标记为掩码：

$$Z_{lon} = \frac{|lon_i - \mu_{lon}|}{\sigma_{lon}},$$

$$Z_{lat} = \frac{|lat_i - \mu_{lat}|}{\sigma_{lat}}$$

4.2.2 速度异常检测（IQR 方法）

● 相邻点速度计算

对连续有效点$P_i(x_i, y_i, t_i)$和$P_j(x_j, y_j, t_j)$，计算欧氏距离、时间差和速度：

$$\Delta d = \sqrt{(x_j - x_i)^2 + (y_j - y_i)^2}, \Delta t = t_j - t_i, v = \frac{\Delta d}{\Delta t}(\Delta t > 0)$$

● 异常速度判定

计算所有速度的四分位数：

➢下四分位数$Q_1 = \mathrm{Percentile}(v, 25\%)$
➢上四分位数$Q_3 = \mathrm{Percentile}(v, 75\%)$
➢四分位距$IQR = Q_3 - Q_1$

设定异常阈值为：

$$v_{\text{thres}} = Q_3 + 1.5 \times IQR$$

4.3 轨迹平滑处理——Savitzky-Golay 滤波器

对有效轨迹点的经纬度序列进行平滑，保留局部趋势的同时抑制噪声。设窗口长度为 w（奇数），多项式阶数为 k，则滤波器系数通过最小二乘拟合确定。

● 构造设计矩阵

对窗口内中心点前后各$m=(w-1)/2$个点，构造范德蒙德矩阵：

$$X=\begin{bmatrix}(-m)^0 & \cdots & (-m)^k\\ \vdots & \ddots & \vdots\\ m^0 & \cdots & m^k\end{bmatrix}$$

- 计算平滑系数

通过最小二乘法求解多项式系数：

$$\beta=(X^TX)^{-1}X^Ty$$

其中 y 为窗口内原始坐标序列。

- 输出平滑值

中心点的平滑值为：

$$\hat{y}_0=\beta_0$$

- 参数选择

程序中设置窗口长度$w=5$（需满足$w\le N_{valid}$），多项式阶数 k=2，以平衡平滑强度与细节保留。

4.4 时间戳与空间坐标插值

4.4.1 时间戳插值

对无法通过前后点插值的掩码点（如轨迹首尾），采用最近邻时间戳：

- 若掩码点位于起始位置，取其后第一个有效点时间戳。
- 若掩码点位于末尾位置，取其前最后一个有效点时间戳。

4.4.2 空间坐标插值

当模型预测失败或连续缺失过长时，采用线性插值：

$$p_mask=\frac{prev_p+next_p}{2},p=lon,lat$$

5 模型建立与解决

5.1 特征工程

特征工程的目标是从 GPS 轨迹数据中提取能够有效描述 MASK 点（缺失点）时空关系的特征，用于模型预测 MASK 点的经度（lon）和纬度（lat）。经过我们的分析，选区的特征需要：捕捉 MASK 点与前后有效点的空间位置关系，反映时间维度上的运动规律，并提供适合模型的数值输入。

5.1.1 特征生成过程

特征工程主要在 generate_train_samples 函数中实现，通过模拟 MASK 点生成训练样本。每个样本包含 6 个特征和 2 个目标值。随机选择索引范围[1, len(df)-1]内的点，确保选取的模拟 MASK 点有前一点。

A. 时间差

前段时间差：

$$\Delta t_{prev} = \left(t_{current} - t_{prev}\right).total_seconds() > 0$$

后段时间差：

$$\Delta t_{next} = (t_{next} - t_{second}).total_seconds() > 0$$

总时间差：

$$total_delta = \Delta t_{total} = \Delta t_{prev} + \Delta t_{next}$$

B. 相对时间比例

表示 MASK 点在前后点时间段中的相对位置：

$$rel_time = \frac{\Delta t_{prev}}{\Delta t_{total}}, \Delta t_{total} \neq 0$$

C. 速度

相邻两点之间的球面距离（基于 Haversine 公式）除以时间差，表示轨迹点的运动速度：

$$v = \frac{Haversine(p_1, p_2)}{\Delta t_{total}}, p_1 = (x_1, y_1), p_2 = (x_2, y_2)$$

设在弧度制下，经度为 Φ，纬度为 λ，则 Haversine 公式：

$$dist = 2R \cdot \sin^{-1}\sqrt{\sin^2\frac{\Phi_2-\Phi_1}{2} + \cos\Phi_1 \cdot \cos\Phi_2 \cdot \sin^2\frac{\lambda_2-\lambda_1}{2}}$$

D. 方向

相邻两点连线的方向角，相对于正北（纬度方向），顺时针计算，表示轨迹的运动方向：

$$direction = \tan^{-1} 2(\Delta x, \Delta y) \cdot \frac{180}{\pi}$$

E. 曲率

基于三点（前一点、当前点、后一点）计算轨迹的局部曲率，表示轨迹的弯曲程度，使用 Haversine 距离计算边长：

$$p_1 = (x_1, y_1), p_2 = (x_2, y_2), p_3 = (x_3, y_3)$$

$$d_1 = Haversine(p_1, p_2), d_2 = Haversine(p_2, p_3), d_3 = Haversine(p_1, p_3)$$

$$curvature = \frac{2\sin\cos^{-1}\frac{d_1^2+d_2^2-d_3^2}{2d_1d_2}}{d_1+d_2}$$

F. 样本格式

每个样本为一个字典,包括前一点和后一点的经纬度、时间差和相对时间比例，样本列表转换为 DataFrame，特征矩阵 X 为：

$$X = [prev_lon, prev_lat, next_lon, next_lat, rel_time, total_delta, prev_speed,$$

$$prev_direction, prev_curvatur, prev_speed, prev_direction, prev_curvatur]$$

使用 StandardScaler 标准化特征矩阵：

$$normalized(f_i) = \frac{f_i - u_i}{\sigma_i}$$

目标矩阵 y 为：

$$y = [target_lon, target_lat]$$

5.1.2 特征的作用与数学解释

每个特征在捕捉轨迹的时空关系中有特定作用，以下结合公式分析其意义：

A. 前一点和后一点的经纬度

定义 MASK 点所在轨迹段的空间位置，提供轨迹的局部几何信息，反映 MASK 点可能的位置范围。

$$x_{current} \approx x_{prev} + \alpha(x_{next} - x_{prev})$$

$$y_{current} \approx y_{prev} + \alpha(y_{next} - y_{prev})$$

模型通过学习其非线性关系，优化 α 的估计。

B. 总时间差

反映前后点之间的时间跨度，间接表示轨迹的采样频率或运动速度。可以提供时间尺度的上下文，辅助模型判断轨迹的动态特性。若总时间差较大，轨迹点较稀疏，MASK 点位置的不确定性增加；若较小，轨迹密集，预测更可靠。

C. 相对时间比例

描述 MASK 点在前后点时间段中的相对位置，捕捉时间维度上的运动规律，帮助模型学习时间与空间的非线性映射。

D. 速度

捕捉轨迹的运动动态，区分快速移动和慢速移动，提供速度上下文，帮助模型预测 MASK 点的合理位置。

E. 方向

捕捉轨迹的几何方向，帮助模型理解运动路径（如直行、左转、右转）。例如，方向变化大的轨迹可能表示转弯，模型可据此调整预测。

F. 曲率

捕捉轨迹的局部几何形状，区分直线（低曲率）、缓弯（中等曲率）和急转弯（高曲率）。帮助模型预测 MASK 点在复杂路径（如城市道路）中的位置。

5.1.3 特征工程的优点

特征矩阵 X 的设计具有显著优点。其数学公式简洁，计算高效，适合大规模轨迹数据处理；特征全面覆盖时空关系，空间特征（前后点经纬度）捕捉轨迹几何形状，时间特征

（相对时间比例和总时间差）反映运动动态；所有特征为数值型，直接适配随机森林模型，支持非线性关系建模；此外，特征生成包含数据验证（如确保无 NaN 和有效时间差），保证鲁棒性。这些优点共同确保特征集在 GPS 轨迹预测任务中高效、准确地支持 MASK 点经纬度预测。

5.2 模型建立

在 GPS 轨迹预测任务中，模型建立是核心步骤，旨在利用特征矩阵 X 和目标矩阵 y 训练一个机器学习模型，以预测轨迹中缺失点（MASK 点）的经纬度。本代码使用随机森林回归模型（Random Forest Regressor）进行预测，下面介绍其实现方法。

随机森林回归是一种集成学习方法，结合多棵回归决策树以提高预测性能，它结合了 Bagging（Bootstrap Aggregating）和随机特征选择两个核心思想。

- 回归决策树基础

一棵回归决策树通过递归分割特征空间，基于特征值将数据划分为子区域，最终在叶子节点输出连续值。

训练目标（损失函数）：最小化均方误差（MSE）：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

预测：对于输入 x，树遍历到对应叶子节点，输出该节点的平均目标值，其中 L 是叶子节点包含的样本集合：

$$\hat{y} = \frac{1}{|L|}\sum_{i\in L} y_i$$

- Bagging（自举聚合法）

通过有放回的随机采样（Bootstrap）生成多个数据子集，每棵树在不同子集上训练，减少模型方差。

给定训练集 D，生成 T 个子集 D_t，每个子集包含 n 个样本，可能重复。每棵树 t 在 D_t 上训练，输出预测。

$$D = \{(lon_i, lat_i)\}_{i=1}^{n}$$

$$D_t = \text{Bootstrap}(D)\,, \text{t} = 1,2,\cdots,\text{T}$$

回归任务中，取所有树的平均值：

$$\hat{y} = \frac{1}{T}\sum_{t=1}^{T}\hat{y}_t(x)$$

● 随机特征选择

在每个节点分裂时，随机选择部分特征（而非全部特征）进行评估，增加树之间的多样性，降低相关性。

假设特征总数为 m，随机选择 m'个特征：$m' = \lfloor m/3 \rfloor$。在节点分裂时，选择最佳特征 f_j 和分割点 s，最小化左右子节点的 MSE：

$$Split = \arg\min_{f_j,s}\left[MSE\left(D_{left}\right) + MSE\left(D_{right}\right)\right]$$

其中，$D_{left} = \{(lon_i, lat_i)|x_{ij} \le s\}$，$D_{right} = \{(lon_i, lat_i)|x_{ij} > s\}$。

随机森林的特征重要性剔除冗余特征：

$$Importance(f_i) = \frac{1}{T}\sum_{t=1}^{T}\Delta MSE(f_i, t)$$

● 方差减少

随机森林通过 Bagging 和随机特征选择降低预测方差，Bagging 减少单棵树方差，随机特征选择降低树之间的相关性，进一步优化方差：

$$Var(\hat{y}) = \frac{Var(\hat{y}_t)}{T} + Cov(\hat{y}_t, \hat{y}_{t'})$$

5.3 模型训练

5.3.1 训练数据的生成和特征标准化

从原始轨迹数据生成训练样本，构造特征矩阵 X 和目标向量 y，为随机森林模型提供输入。具体生成过程是：遍历 train 目录中的.txt 文件；使用 parse_trajectory 函数解析文件，生成 DataFrame，包含列：timestamp、lon、lat、line_num；调用 calculate_trajectory_features 函数，计算动态特征（速度、方向、曲率）；使用 generate_train_samples 函数为每个轨迹点模拟 MASK 点，生成训练样本。

特征标准化目的是消除特征间的尺度差异（如速度 10-30 米/秒和经纬度 116 度），提高模型对动态特征（速度、曲率）的利用效率。训练数据通过 generate_train_samples 从轨迹文件生成，包含 12 个特征（静态+动态）和目标经纬度。动态特征（速度、曲率）使用 Haversine 公式计算，确保地理准确性。特征标准化通过 StandardScaler 统一尺度，改善模

型性能。

5.3.2 训练数据的划分

将训练数据划分为训练集和验证集，用于模型训练和性能评估。训练集用于拟合模型，验证集用于评估模型在未见过数据上的泛化能力。

我们规定 20%数据作为验证集，80%作为训练集。固定随机种子为 42，确保划分结果可重复。训练集用于拟合随机森林模型，学习特征与目标的映射；验证集评估模型泛化能力，计算 MSE。

$$f(X) = [target_lon, target_lat]$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_{target,i} - \hat{y}_i\right)^2$$

5.3.3 模型训练过程

模型集成多棵决策树，通过平均预测减少过拟合。适合高维特征和非线性关系，适应轨迹预测的复杂模式。

超参数如下：

```
n_estimators=100, random_state=42
```

训练过程如下：

- 初始化模型：创建随机森林模型，设置 100 棵树。
- 拟合数据

使用训练集训练模型，每棵决策树基于随机子集（特征和样本）构建，随机选择部分样本（Bootstrap 采样）和特征，预测为所有树的平均输出。

$$\hat{y} = \frac{1}{T}\sum_{t=1}^{T} tree_i(X)$$

5.3.4 模型训练过程的优势

A. 丰富的特征矩阵

特征矩阵包含 12 个特征（6 静态+6 动态），提供全面的时空和动态信息。静态特征捕

捉 MASK 点的时空上下文，动态特征（速度、方向、曲率）反映运动和几何特性，适合复杂轨迹（如城市道路）。Haversine 公式确保速度和曲率的地理准确性（米/秒、1/米）。

B. 随机森林的鲁棒性

集成 100 棵决策树，通过平均预测减少过拟合，另外，随机特征和样本选择增强模型对噪声和异常值的鲁棒性。适合高维特征和非线性关系，适应轨迹预测的复杂模式。

C. 特征标准化

解决单位差异（如经纬度和速度），提高模型对动态特征的利用效率。确保模型性能稳定，避免某些特征因数值较大而主导。

6 模型检验与评估

6.1 模型检验与评估概述

评估目标是评估随机森林模型在训练集、验证集和测试集上的预测性能，量化 MASK 点经纬度预测的准确性。

验证集评估：在 main 函数中，使用训练数据划分的验证集计算 MSE，评估模型泛化能力。

测试集评估：在 predict_and_evaluate 函数中，使用训练掩码数据（train_masked）和真实轨迹数据（train）计算多种指标（MSE、RMSE、MAE、Frechet、DTW），并可视化结果。

6.2 模型检验与评估详细描述

在训练掩码数据（train_masked）上预测 MASK 点，并与真实轨迹（train）比较，全面评估模型性能。

表 1 轨迹评估指标统计表格

指标	平均值	中位数	标准差	最小值	最大值
MSE	0.002315	0.000704	0.008607	0.000014	0.052138
RMSE	0.030872	0.026542	0.036911	0.003777	0.228338
MAE	0.023408	0.020022	0.027990	0.003167	0.172534
Frechet	0.068813	0.051728	0.085499	0.008343	0.526626
DTW	1.951650	1.622030	2.469206	0.283719	14.955440

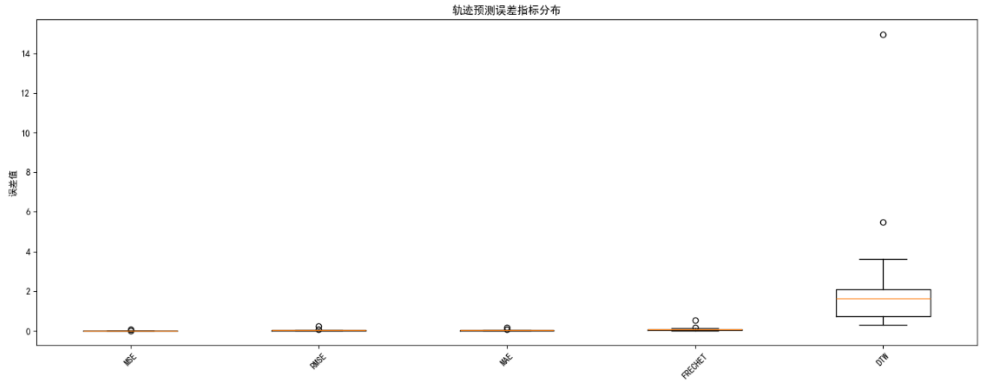

图 6 轨迹误差分布箱线图

6.2.1 均方误差（MSE）

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

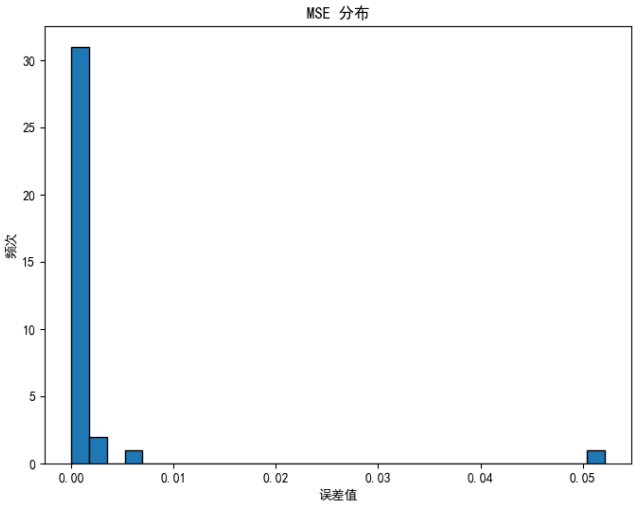

图 7 MSE 分布条形图

6.2.2 均方根误差（RMSE）

$$RMSE = \sqrt{MSE}$$

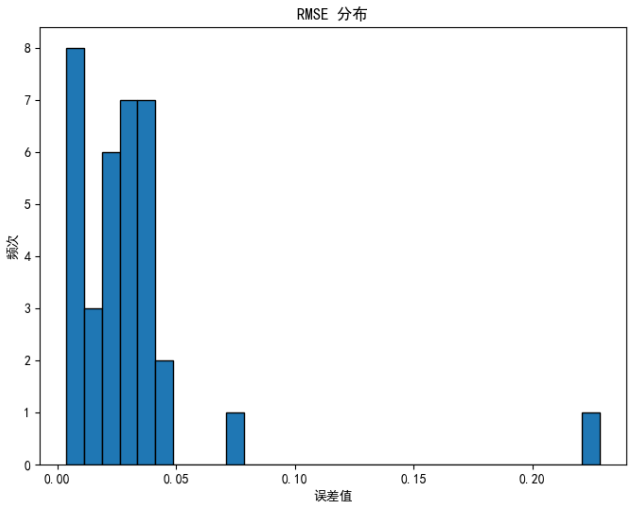

图 8 RMSE 分布条形图

6.2.3 平均绝对误差（MAE）

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

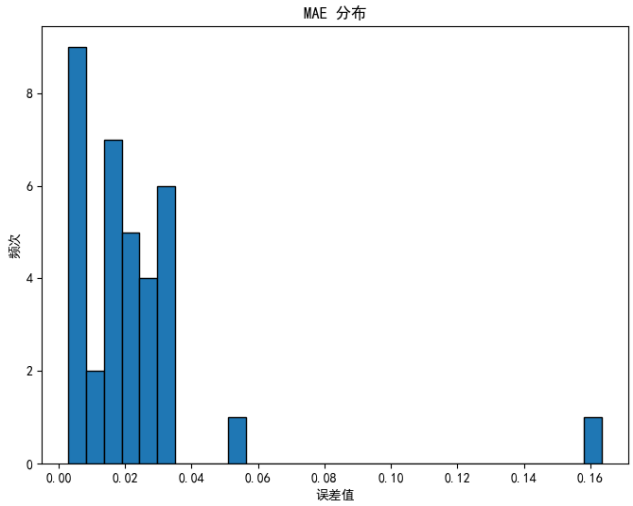

图 9 MAE 分布条形图

6.2.4 Frechet 距离

$$Frechet = \inf_{\alpha,\beta}\max_{t\in[0,1]}\left\|pred\big(\alpha(t)\big) - true\big(\beta(t)\big)\right\|$$

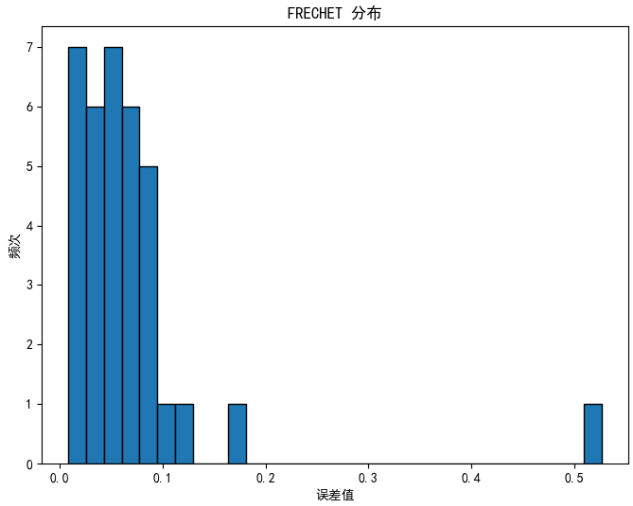

图 10 Frechet 距离分布条形图

6.2.5 动态时间规整（DTW）

$$DTW = \min_{alignment} \sum_{(i,j)\in alignment} \|pred_i - true_j\|$$

$$DTW(i,j) = \|pred_i - true_j\| + \min \begin{cases} DTW(i-1,j) \\ DTW(i,j-1) \\ DTW(i-1,j-1) \end{cases}$$

其中，alignment 是预测轨迹和真实轨迹点之间的单调匹配路径。

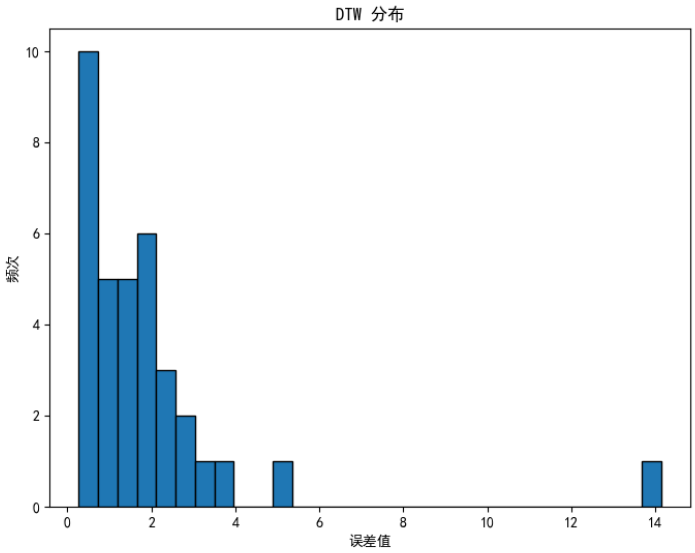

图 11 DTW 分布条形图

6.3 模型轨迹预测可视化展示

visualize_predictions 函数通过绘制预测轨迹（红色线条）、掩码轨迹的非掩码点（蓝色圆点）和真实轨迹（绿色线条），生成 GPS 轨迹预测的对比可视化图，分别从 train_predictions、train_masked 和 train 目录读取数据。它将轨迹文件解析为 DataFrame，处理标记为 MASK 的掩码点，并在图中以红色文本标注掩码点数量。针对每个文件，函数生成带有网格和图例的清晰图像。该可视化通过直观展示预测精度和轨迹形状偏差，辅助评估模型性能。下面展示一些可视化的实例：

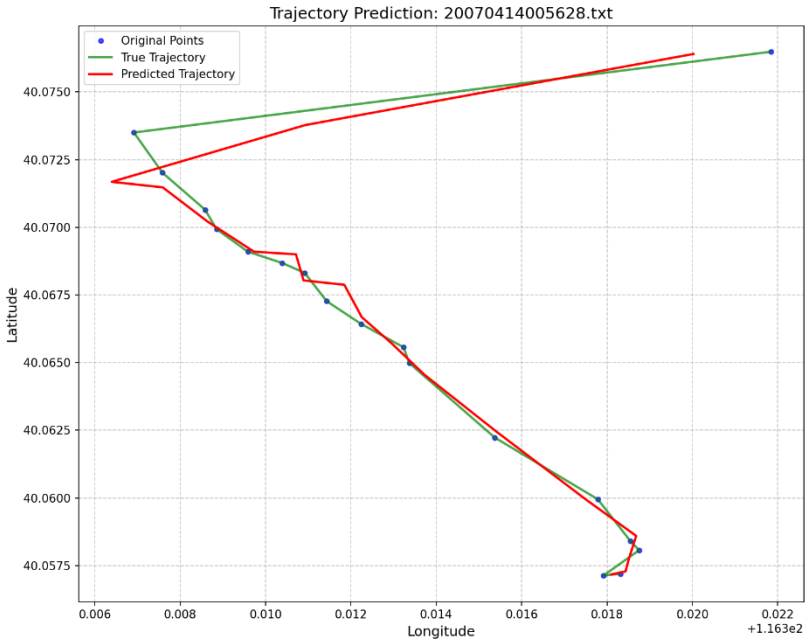

图 12 模型轨迹预测可视化示例图一

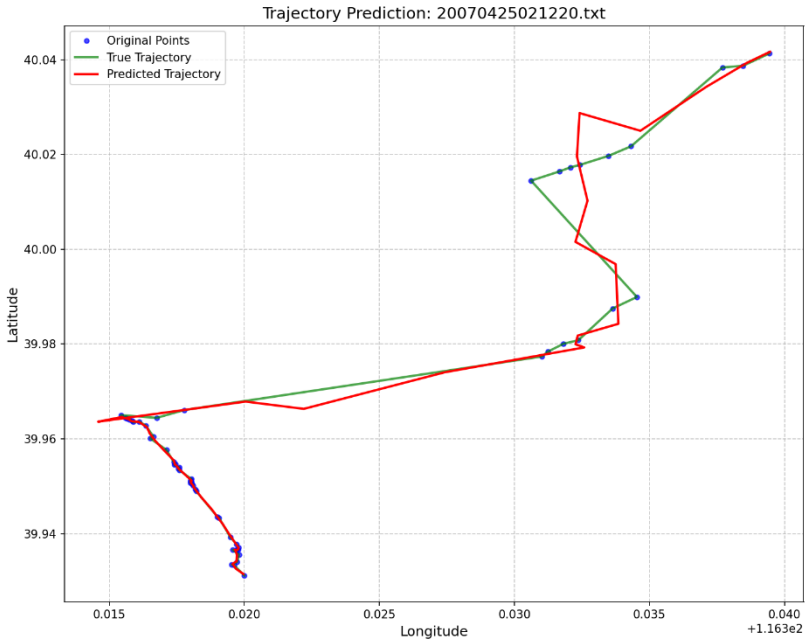

图 13 模型轨迹预测可视化示例图二

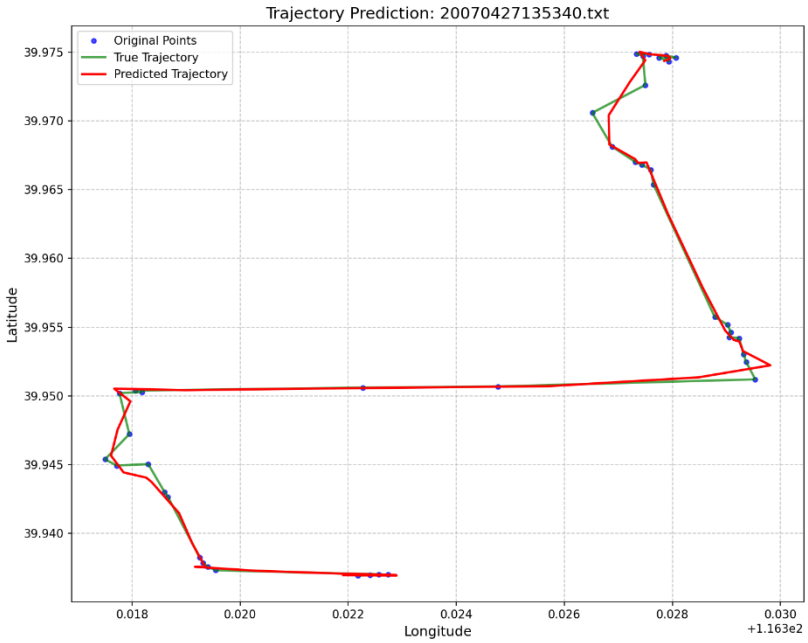

图 14 模型轨迹预测可视化示例图三

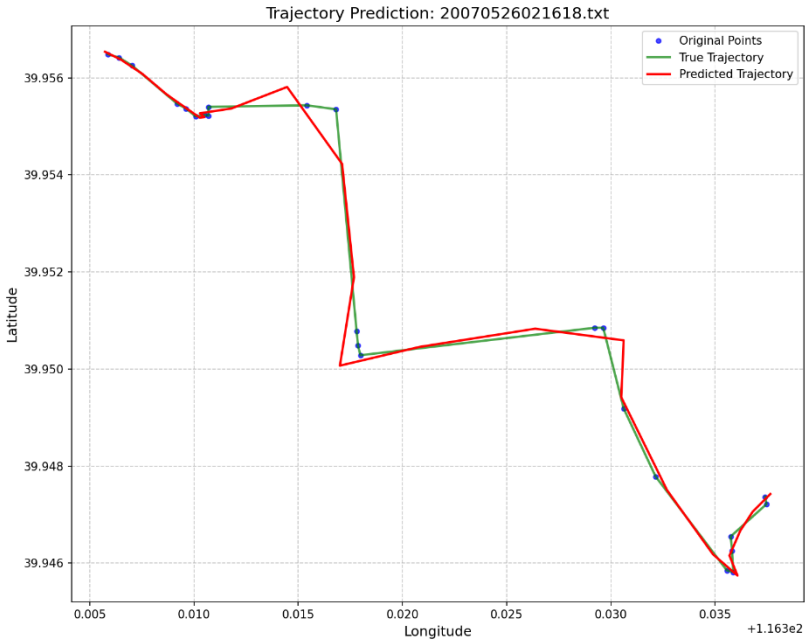

图 15 模型轨迹预测可视化示例图四

7 总 结

本研究针对轨迹修复的数学建模问题，提出了一种基于随机森林回归的混合预测方法，结合传统插值与机器学习技术，成功实现了 GPS 轨迹数据中缺失点的坐标补全。研究从数据预处理、特征工程、模型构建到结果评估，完整覆盖了轨迹修复任务的各个环节，取得了较好的预测精度和鲁棒性。

在数据预处理阶段，通过 Z-score 方法和 IQR 方法有效清洗了坐标和速度异常值，采用 Savitzky-Golay 滤波器平滑轨迹，保留运动趋势，同时利用线性插值为掩码点分配时间戳。这些步骤显著提高了数据质量，为后续建模奠定了基础。

在特征工程方面，设计了包含空间（前后点经纬度）、时间（相对时间比例、总时间差）和动态（速度、方向、曲率）特征的 12 维特征矩阵。特征通过 Haversine 公式和标准化处理，确保了地理准确性和模型适应性，全面捕捉了轨迹的时空特性。

在模型构建中，选用随机森林回归模型，利用其集成学习和随机特征选择的优势，处理轨迹数据的非线性关系和高维特征。模型通过训练集和验证集的划分优化参数，结合线性插值作为后备策略，增强了预测的鲁棒性。

在模型评估中，采用多维评估体系，包括点级精度指标（MSE、RMSE、MAE）和轨迹相似性指标（Frechet 距离、DTW）。结果显示，模型在训练掩码数据上的平均 MSE 为 0.002315，RMSE 为 0.030872，MAE 为 0.023408，Frechet 距离为 0.068813，DTW 为 1.951650，表明预测轨迹与真实轨迹在局部坐标和整体形态上均具有较高一致性。可视化结果进一步直观展示了修复轨迹与真实轨迹的吻合度，验证了模型的有效性。

为进一步提升轨迹修复的精度与适应性，未来可从以下方向改进：首先，引入路网匹配信息，利用道路拓扑约束优化预测结果；其次，采用 LSTM 或时空图神经网络等深度学习模型，捕捉轨迹的时序和空间依赖，改善对长序列缺失的修复效果；此外，优化异常值检测算法，适应非正态分布或非对称速度场景，进一步提高数据预处理的鲁棒性和模型在复杂场景下的预测能力和泛化性能。

参考文献

[1] Scornet, E., Biau, G., & Vert, J. (2014). Consistency of Random Forests. *Annals of Statistics*, 43, 1716-1741.

[2] Wang, C., L., Li, R., Durrani, T., & Zhang, H. (2019). Exploring Trajectory Prediction Through Machine Learning Methods. *IEEE Access*, 7, 101441-101452.

[3] Papathanasopoulou, V., Spyropoulou, I., Perakis, H., Gikas, V., & Andrikopoulou, E. (2022). A Data-Driven Model for Pedestrian Behavior Classification and Trajectory Prediction. *IEEE Open Journal of Intelligent Transportation Systems*, 3, 328-339.

[4] Guest, P. G. (2012). *Numerical methods of curve fitting*. Cambridge University Press.

[5] Wang, Y., Zhang, D., Liu, Y., & Tan, K. (2020). Trajectory Forecasting With Neural Networks: An Empirical Evaluation and A New Hybrid Model. *IEEE Transactions on Intelligent Transportation Systems*, 21, 4400-4409.