

实验报告

实验名称 金融反欺诈中的动态社交网络研究

课程名称 网络数据风控技术

专业班级：2023 级数据科学与大数据技术专业

学生姓名：学号：

指导教师：叶晨成绩：

实验日期：2025.12.10-2025.12.30

同济大学

一、 实验背景介绍与问题描述

随着互联网金融的蓬勃发展，欺诈手段逐渐呈现出专业化、团伙化和隐蔽化的特征。传统的反欺诈模型往往基于“独立同分布”假设，仅关注单一用户的属性特征，难以捕捉隐藏在复杂社交网络中的关联风险。而在金融业务中，用户填写的“紧急联系人”构成了强关联的社交网络，欺诈分子往往倾向于在相互之间进行填报或聚集，这种拓扑结构包含了极高的风控价值。因此，利用图神经网络（GNN）深度挖掘用户间的关联和影响力，已成为识别潜在欺诈的关键技术。

本实验的数据集源自企业真实业务，构建了一个全连通的社交网络有向动态图。图中节点代表注册用户，有向边代表紧急联系人填报关系，并包含多种边类型及 17 维节点特征。数据标签共有四类，其中正常用户（Class 0）与欺诈用户（Class 1）被称为前景节点，是分类任务的核心对象；而占据较大数据比例的 Class 2 和 Class 3 被称为背景节点。

本实验的核心问题是如何在包含大量背景节点的复杂图结构中，精准识别前景节点中的欺诈用户。这要求模型不仅要处理节点特征，更要充分利用所有节点（包括背景节点）构成的拓扑结构进行信息聚合与传播，从海量数据中区分出正常用户与欺诈用户，实现对测试集样本的准确风险预测。

二、 国内外相关研究工作介绍

随着金融反欺诈对抗的升级，欺诈检测技术已从早期的专家规则系统和传统统计机器学习（如逻辑回归、SVM、XGBoost），向基于图数据的深度学习方法演进。传统方法多基于独立同分布（I.I.D.）假设，仅利用用户的属性特征（如年龄、收入、设备信息），往往忽略了用户之间通过“紧急联系人”、“设备共享”、“转账关系”构成的复杂拓扑结构，难以应对团伙欺诈和关联风险。

1. 基础图神经网络（GNNs）

图神经网络通过消息传递机制（Message Passing）聚合邻域信息，能够同时利用节点特征和图结构信息。Kipf 等人（2016）提出的 GCN（图卷积网络）^[1]是该领域的基石，它利用谱图理论进行一阶近似卷积，实现了端到端的节点分类。Veličković 等人（2017）提出的 GAT（图注意力网络）引入了注意力机制，允许模型为不同的邻居节点分配不同的权重^[2]，这对于反欺诈尤为重要，因为正常用户的邻居中可能包含噪声，注意力机制能有效聚焦关键风险节点。Hamilton 等人（2017）提出的 GraphSAGE 则通过邻居采样和聚合函数，解决了大规模图的归纳式学习（Inductive Learning）问题，使得模型能应用于未见过的节点^[3]。

2. 面向金融反欺诈的图算法研究

金融场景下的图数据具有异构性、标签稀疏性和类别极度不平衡等特点，学术界和工业界对此进行了针对性研究：

处理异构图与多关系：本次大作业涉及多种边类型（edge_type）。Schlichtkrull 等人（2018）提出的 R-GCN（关系图卷积网络）专门用于处理多关系图，为不同类型的边学习不同的变换矩阵^[4]。Wang 等人（2019）提出的 HAN（异构图注意力网络）则通过元路径（Meta-path）机制，捕捉不同类型节点和边之间的语义关联^[5]。

现实中，欺诈分子常通过连接大量正常用户来“伪装”自己（Camouflage），导致传统 GNN 效果下降。Dou 等人（2020）提出的 Care-GNN 结合了强化学习与图神经网络，通过标签感知和邻居选择机制，剔除无关或伪装的邻居^[6]，显著提升了欺诈检测性能。此外，针对正负样本比例悬殊的问题，PC-GNN（Liu 等人，2021）提出了基于标签平衡的采样策略（Pick and Choose），通过欠采样正常节点和过采样欺诈节点来优化分类边界^[7]。

3. 大规模图计算与背景节点利用

在包含大量背景节点的超大规模图中，全图训练面临内存溢出挑战。ClusterGCN（Chiang 等人，2019）^[8]和 GraphSAINT（Zeng 等人，2019）^[9]等算法通过基于图聚类或随机游走的子图采样技术，在保证连通性的前提下将大图分解为小批次（Mini-batch）进行训练，不仅提高了计算效率，还能有效利用背景节点传递的信息，增强模型的泛化能力。

综上所述，当前的研究趋势在于如何设计能够处理异构边信息、具备抗伪装能力的注意力机制，以及如何在大规模网络中高效地聚合全局信息，这为解决本题提供了坚实的理论基础。

三、特征工程与模型方法

针对金融反欺诈场景中数据长尾分布、标签极度稀疏（Class 0/1 为前景，Class 2/3 为背景）以及欺诈团伙伪装性强等挑战，本实验提出了一种融合全局语义与局部拓扑的混合图神经网络框架（Hybrid Hetero-GNN with Transformer）。该框架包含三个核心阶段：基于统计与神经网络的特征工程、多视图并行图编码器、以及基于监督对比学习的优化策略。

1. 数据预处理与特征工程

原始数据集包含 17 维脱敏后的节点特征。为了消除量纲差异并增强特征的非线性表达能力，我们实施了由浅入深的特征处理流程。

①鲁棒特征标准化（Robust Scaling）

金融数据往往包含极端异常值，传统的 Z-Score 标准化容易受离群点影响导致分布偏移。代码中采用了基于中位数和四分位距（IQR）的鲁棒标准化策略。对于特征矩阵 $X \in \mathbb{R}^{N \times F}$ 中的特征 x ，变换公式为：

$$x_{norm} = \frac{x - \text{median}(x)}{Q_{75}(x) - Q_{25}(x) + \epsilon}$$

其中 Q_{75} 和 Q_{25} 分别为上、下四分位数， ϵ 为数值稳定常数。随后对数据进行

$[-10,10]$ 的数值截断 (Clipping), 彻底消除极端噪声。

②图拓扑特征增强

为了显式利用网络结构信息, 代码通过 `add_graph_features` 函数计算节点的度 (Degree)。考虑到社交网络度分布的幂律特性, 我引入对数变换以平滑分布, 并将归一化后的度特征拼接到原始特征中, 使模型能够区分网络边缘的孤立用户与核心活跃用户:

$$x_{new} = [x_{norm} \parallel \text{Norm}(\deg(v)) \parallel \text{Norm}(\log(\deg(v) + 1))]$$

③神经特征增强 (Neural Feature Augmentation)

为了进一步挖掘特征间的高阶交互关系, 我们在模型输入端设计了 `FeatureAugmentation` 模块。该模块并行通过 `Tanh` 和 `Sigmoid` 激活函数将原始特征映射到非线性空间, 类似于残差连接的变体:

$$h_{aug}^{(0)} = [x_{new} \parallel \tanh(W_1 x_{new} + b_1) \parallel \sigma(W_2 x_{new} + b_2)]$$

这种设计将输入维度进行了扩充 ($F \rightarrow F + 2 \times F_{aug}$), 为后续 GNN 提供了更丰富的信息基底。

2. 模型架构: 多分支混合图神经网络

单一的图卷积算子难以同时应对全图同质性、邻域异质性和复杂的子图结构。因此, 本实验设计了 `HeteroGNN` 类, 采用多分支并行聚合 (Multi-Branch Aggregation) 策略, 在每一层同时利用四种主流 GNN 算子提取多视图特征, 随后引入 `Transformer` 进行全局语义交互。

假设第 l 层的输入为 $H^{(l-1)}$, 该层包含以下四个并行分支:

①分支一: 图卷积网络 (GCN) ^[1]

利用谱图理论的一阶近似, GCN 擅长捕捉全图的平滑结构特征, 通过对称归一化的拉普拉斯矩阵进行全图信息聚合:

$$H_{GCN}^{(l)} = \sigma(\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} H^{(l-1)} W_{GCN}^{(l)})$$

②分支二: GraphSAGE ^[3]

GraphSAGE 采用归纳式学习 (Inductive Learning) 范式, 通过聚合邻居特征来生成节点嵌入。代码中使用 `SAGEConv`, 能够有效利用大量背景节点 (Class 2/3) 的信息进行传播:

$$H_{SAGE}^{(l)} = W_{SAGE}^{(l)} \cdot \text{Concat}(H^{(l-1)}, \text{Mean}_{u \in \mathcal{N}(v)} H_u^{(l-1)})$$

③分支三: 图注意力网络 (GAT) ^[2]

针对欺诈分子刻意连接正常用户进行“伪装”的问题, GAT 分支引入自注意力机制, 动态为不同邻居分配权重 α_{vu} , 从而过滤噪声邻居:

$$\alpha_{vu} = \text{softmax}_u \left(\text{LeakyReLU} \left(a^T [W H_v^{(l-1)} \parallel W H_u^{(l-1)}] \right) \right)$$

$$H_{GAT}^{(l)} = \sum_{u \in \mathcal{N}(v)} \alpha_{vu} W H_u^{(l-1)}$$

④分支四：图同构网络（GIN）^[10]

为了识别特定团伙的拓扑结构，引入具有 Weisfeiler-Lehman 测试强度 GIN 算子，通过 MLP 对聚合结果进行非线性变换：

$$H_{GIN}^{(l)} = \text{MLP}^{(l)} \left((1 + \epsilon) \cdot H_v^{(l-1)} + \sum_{u \in \mathcal{N}(v)} H_u^{(l-1)} \right)$$

⑤多视图融合与深度堆叠

上述四个分支的输出在特征维度进行拼接（Concatenation），形成包含多重物理意义的混合特征。融合后的特征经过 Batch Normalization、ReLU 激活和 Dropout 处理：

$$H_{fused}^{(l)} = \text{Dropout} \left(\text{ReLU} \left(\text{BN} \left([H_{GCN}^{(l)} \parallel H_{SAGE}^{(l)} \parallel H_{GAT}^{(l)} \parallel H_{GIN}^{(l)}] \right) \right) \right)$$

这种并行架构不仅丰富了特征表达，还通过集成不同算子的优势提高了模型的鲁棒性。

⑥全局语义增强：Transformer 模块^[11]

虽然 GNN 擅长捕捉局部邻域信息，但随着层数加深容易出现过平滑（Over-smoothing），且难以捕捉长距离依赖。为此，我设计模型在 GNN 层之后引入了 TransformerEncoderLayer。Transformer 将节点特征视为序列，通过多头自注意力机制（Multi-Head Self-Attention, MSA）实现全图节点的语义交互：

● 全局自注意力计算

对于输入特征矩阵 $H \in \mathbb{R}^{N \times d}$ ，模型将其映射为查询（Query）、键（Key）和价值（Value）矩阵：

$$Q = HW_Q, K = HW_K, V = HW_V$$

通过点积注意力计算全局相关性得分，使得每个节点都能根据语义相似度关注图中的其他所有节点，而不仅仅是物理连接的邻居：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

● 语义特征重构

全局交互后的特征经过层归一化（LayerNorm）和前馈神经网络（FFN）处理，并引入残差连接以防止梯度消失：

$$H' = \text{LayerNorm} \left(H_{fused} + \text{MSA}(H_{fused}) \right)$$

$$H_{global} = \text{LayerNorm} \left(H' + \text{FFN}(H') \right)$$

这一机制能够有效识别那些在拓扑上距离较远、但行为模式高度相似的潜在欺

诈团伙成员。

⑦标签传播机制 (Label Propagation) ^[12]

金融反欺诈领域普遍存在“同质性假设”(Homophily Assumption)，即欺诈用户倾向于与欺诈用户建立连接。为了充分利用已知的标签信息并平滑预测结果，代码中实现了 LabelPropagation 模块。

该模块基于图的半监督学习原理，将标签信息作为一种信号在图结构上进行扩散。假设初始标签矩阵为 $Y^{(0)}$ （仅训练集节点有值，其余为 0），传播过程遵循以下迭代公式：

● 归一化传播矩阵

首先计算对称归一化的邻接矩阵，用于控制传播强度：

$$\hat{A} = D^{-1/2} A D^{-1/2}$$

其中 D 为度矩阵， A 为邻接矩阵。

● 迭代扩散更新

在第 k 次迭代中，节点不仅接收邻居节点的标签信息，还保留一定比例的初始信息。更新公式为：

$$Y^{(k+1)} = \alpha \hat{A} Y^{(k)} + (1 - \alpha) Y^{(0)}$$

其中 α 为传送概率（代码中设为 0.9），用于平衡邻居影响与自身初始标签的权重。

● 标签钳制 (Label Clamping)

为了防止已知标签在传播过程中被噪声淹没，每次迭代后会将训练集节点的预测值重置为真实标签：

$$Y_{train}^{(k+1)} = Y_{train}^{(0)}$$

虽然 GNN 模型本身具备强大的特征提取能力，但标签传播模块提供了一种非参数化的、基于纯结构的显式平滑机制，能够作为一种正则化手段或辅助分支，进一步增强模型对背景节点信息的利用效率。

3. 损失函数与优化策略

为了解决类别不平衡和提升嵌入质量，我们采用了混合损失函数进行端到端优化。

①Focal Loss ^[13]

针对正负样本比例失衡 (Class 0 和 Class 1)，使用 Focal Loss 替代标准交叉熵，降低易分类样本的权重，强制模型关注困难样本：

$$L_{Focal} = -\alpha(1 - p_t)^\gamma \log(p_t)$$

其中 p_t 为预测概率，实验中设置 $\gamma = 2.0$ 。

②监督对比学习 (Supervised Contrastive Learning) ^[14]

为了获得类内紧凑、类间分离的嵌入表示，我们在 SupervisedContrastiveGNN 中引入了对比损失。在投影空间中，拉近同类节点的距离，推开异类节点：

$$L_{SupCon} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(z_i \cdot z_p / \tau)}{\sum_{a \in A(i) \setminus \{i\}} \exp(z_i \cdot z_a / \tau)}$$

其中 z 为归一化后的嵌入向量， τ 为温度系数， $P(i)$ 为正样本集合。

③总优化目标

最终的损失函数由分类损失和对比损失加权组成：

$$L_{total} = L_{Focal} + \lambda L_{SupCon}$$

结合梯度裁剪（Gradient Clipping）和 ReduceLROnPlateau 学习率衰减策略，该框架能够在大规模图数据上稳定收敛，有效识别隐藏在正常用户中的欺诈节点。




图 1 HeteroGNN 模型结构图

四、 实验结果

1. 实验环境与参数设置

我在训练过程中采用了固定的超参数配置。模型优化器选用 AdamW，以利用其权重衰减（Weight Decay $1e-5$ ）特性防止过拟合。初始学习率设为 0.0005，并配合 ReduceLROnPlateau 调度器，当验证集 AUC 在 30 个 Epoch 内未提升时，将学习率减半，最小下探至 $1e-6$ 。

训练最大轮次（Epochs）设为 1000，并引入早停机制（Early Stopping），Patience 设为 100，以在模型性能不再提升时及时终止训练，节省算力并保留最佳权重。损失函数采用 Focal Loss 以应对正负样本比例严重失衡的问题。




图 2 训练过程中学习率变化曲线

2. 评估标准与指标选择

在金融反欺诈场景中，数据集呈现典型的长尾分布，正常用户（Class 0）占据绝大多数，而欺诈用户（Class 1）极为稀疏。在这种情况下，传统的准确率（Accuracy）指标失效，因为一个将所有样本均预测为“正常”的平凡分类器也能获得极高的准确率，但却无法识别任何风险。因此，本实验选用 ROC-AUC（Area Under the Receiver Operating Characteristic Curve）作为核心评估指标。

ROC 曲线由横坐标 假阳性率 FPR 和纵坐标真阳性率 TPR 构成，两者的定义如下：

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

其中， TP 为被正确识别的欺诈样本， FN 为漏报的欺诈样本。AUC 值即为 ROC 曲线下的面积，其数学意义可解释为：随机抽取一个正样本（欺诈用户） x^+ 和一个负样本（正常用户） x^- ，模型对正样本的预测得分高于负样本的概率：

$$AUC = P(\text{Score}(x^+) > \text{Score}(x^-))$$

相比于依赖固定阈值的指标（如 Precision/Recall），AUC 衡量的是模型对样本风险的排序能力。在风控业务中，我们更关注能否将高风险用户排在列表前列，以便业务人员优先审核，因此 AUC 是衡量模型优劣的最稳健指标。

3. 训练动态与收敛性分析

基于训练日志及生成的 AUC 曲线图，我可以将模型的训练过程划分为三个显著阶段，这反映了模型对图结构信息的提取深度的变化。

①快速特征提取期 (Epoch 0-200)

曲线显示，模型在初始阶段性能迅速攀升，AUC 从 0.55 左右跃升至 0.94。这表明我们设计的特征工程（如度特征的对数变换、鲁棒标准化）显著降低了学习难度，同时 HeteroGNN 中的 GCN 和 GraphSAGE 分支迅速捕捉到了显性的邻域聚集特征（即欺诈分子的局部抱团现象）。

②结构微调与对抗期 (Epoch 200-800)

在此阶段，AUC 增长放缓并呈现微小震荡，但整体趋势依然向上。这是因为模型开始处理难以区分的“伪装”样本。此时，GAT 分支的注意力机制和 Transformer 的全局交互开始发挥作用，通过抑制噪声邻居权重和捕捉长距离依赖，逐步优化分类边界。

③极致收敛期 (Epoch 800-1000)

得益于 ReduceLROnPlateau 策略，学习率在后期自动衰减。模型在损失曲面的极小值附近进行精细搜索，最终在第 987 轮达到最佳验证集性能：

Best Valid AUC = 0.9796

观察曲线中蓝色（训练集）与橙色（验证集）线条，两者始终保持紧密贴合，未出现明显的训练集 AUC 远高于验证集的现象。这证明模型未发生过拟合现象。该优异的泛化能力归功于模型中引入的 Dropout、权重衰减以及监督对比学习（Contrastive Learning）带来的正则化效应。




图 3 训练过程中 ROC 变化曲线

4. 预测分布与概率校准分析

根据推理日志生成的统计数据，我对测试集（Test Set）的预测概率分布进行了量化分析：

Mean 0.1314
Max 0.2983
Min 1e-6

这里出现了一个值得注意的现象：预测概率的最大值仅为 0.2983，远低于通常作为分类阈值的 0.5。这一现象并非模型失效，而是由以下两个数学与工程因素共同导致的：

- **Focal Loss 的数值抑制**

本实验采用 Focal Loss 优化目标，由于 $\gamma = 2.0$ 的设定，模型极大地降低了易分类负样本（即绝大多数正常用户）的权重。为了最小化全局损失，模型倾向于输出保守的概率值，而不是极端的 0 或 1。

- **排序优于校准**

结合 0.9796 的高 AUC 值与 0.298 的最大预测值，说明模型是一个极佳的排序器而非校准的概率估计器。尽管欺诈样本的绝对预测概率不高（例如 0.25），但这一数值已经显著高于正常样本的预测值（均值 0.13）。

这意味着在实际应用中，判定欺诈的阈值（Threshold）不应设为 0.5，而应根据验证集的 Precision-Recall 曲线选取一个较低的值（如 $\tau = 0.20$ ）。在此阈值下，模型依然能够精确地圈定高风险的欺诈团伙。

在和鲸平台上，程序采用 sklearn.metrics 中的 roc_curve 和 auc 计分，将 auc 结果乘以 100 并保留 3 位小数。我的模型输出结果的得分为 97.985，证明了模型的有效性。

排行榜

排名	昵称	分数	提交次数	最佳成绩提交时间	最后成绩提交时间
1	吴寒雨	99.998	30	2025/12/22 17:02	2025/12/22 17:02
2	徐志铭	99.998	19	2025/12/28 11:20	2025/12/29 20:28
3	於之翔	99.926	48	2025/12/26 13:22	2025/12/26 13:22
4	邝家琪	99.246	24	2025/12/27 18:42	2025/12/27 19:03
5	杨安琪	99.088	14	2025/12/19 15:21	2025/12/19 15:21
6	刘彦	97.985	6	2025/12/26 04:42	2025/12/26 04:42

图 4 和鲸平台排行榜截图[2025-12-30 20:00]

5. 实验小结

实验结果表明，提出的融合全局语义与局部拓扑的 HeteroGNN 模型在处理大规模动态反欺诈图数据时表现优异。模型成功利用了背景节点和异构边信息，验证集和测试集 AUC 接近 0.98，证明了其在复杂网络中精准识别欺诈用户的能力。

同时，模型训练曲线平滑，且早停机制与学习率衰减策略有效保证了模型收敛于全局最优解附近。预测分布统计揭示了风控模型“低概率、高排序”的典型特征，验证了使用 AUC 而非 Accuracy 作为核心指标的正确性。

五、 结论和展望（限 500 字以内）

本实验针对金融反欺诈场景中数据长尾分布、标签极度稀疏及欺诈手段隐蔽等挑战，设计并实现了一个融合全局语义与局部拓扑的 HeteroGNN 反欺诈框架。通过引入鲁棒特征工程、多分支并行图算子（GCN/SAGE/GAT/GIN）以及 Graph Transformer 全局交互模块，模型成功打破了图卷积的局部感受野限制，有效捕捉了潜藏在复杂社交网络中的长距离依赖和团伙结构。配合监督对比学习与 Focal Loss 的联合优化策略，模型在严重不平衡的数据集上实现了收敛，验证集 AUC 达到 0.9796，平台测试分数达到 97.985（测试集 AUC $\times$ 100），证明了该方法在利用海量背景节点辅助识别前景欺诈用户方面的卓越性能与强泛化能力。

尽管模型表现优异，未来工作仍可从以下三个维度进行深化：

- **概率校准 (Probability Calibration)**: 当前模型预测值虽然排序准确 (AUC 高)，但绝对概率值普遍偏低 (Max<0.3)。未来可引入 Isotonic Regression 或 Platt Scaling 等后处理技术，将输出映射为具有真实置信度意义的概率，以便业务端设定更直观的阈值。
- **动态时序建模**: 目前的图构建主要基于静态拓扑，未来可引入时序图神经网络 (如 TGN)，显式建模用户行为和关联关系随时间的演变轨迹，捕捉欺诈行为的动态突变特征。
- **模型可解释性**: 金融风控对透明度要求极高，后续可结合 GNNExplainer 等工具，可视化关键风险邻居与核心路径，为风控专家的审核提供直观依据。

六、 参考文献

- [1] Kipf T N. Semi-supervised Classification with Graph Convolutional Networks[J]. arXiv preprint arXiv:1609.02907, 2016.
- [2] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[J]. stat, 2017, 1050(20): 10-48550.
- [3] Hamilton W, Ying Z, Leskovec J. Inductive Representation Learning on Large Graphs[J]. Advances in neural information processing systems, 2017, 30.
- [4] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling Relational Data with Graph Convolutional Networks[C]//European semantic web conference. Cham: Springer International Publishing, 2018: 593-607.
- [5] Wang X, Ji H, Shi C, et al. Heterogeneous Graph Attention Network[C]//The world wide web conference. 2019: 2022-2032.
- [6] Dou Y, Liu Z, Sun L, et al. Enhancing Graph Neural Network-based Fraud Detectors Against Camouflaged Fraudsters[C]//Proceedings of the 29th ACM international conference on information & knowledge management. 2020: 315-324.
- [7] Liu Y, Ao X, Qin Z, et al. Pick and Choose: A GNN-based Imbalanced Learning

Approach for Fraud Detection[C]//Proceedings of the web conference 2021. 2021: 3168-3177.

[8] Chiang W L, Liu X, Si S, et al. Cluster-GCN: An Efficient Algorithm for Training Deep and Large Graph Convolutional Networks[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 257-266.

[9] Zeng H, Zhou H, Srivastava A, et al. GraphSAINT: Graph Sampling Based Inductive Learning Method[J]. arXiv preprint arXiv:1907.04931, 2019.

[10] Xu K, Hu W, Leskovec J, et al. How Powerful are Graph Neural Networks?[J]. arXiv preprint arXiv:1810.00826, 2018.

[11] Dwivedi V P, Bresson X. A Generalization of Transformer Networks to Graphs[J]. arXiv preprint arXiv:2012.09699, 2020.

[12] Zhu X, Ghahramani Z. Learning from Labeled and Unlabeled Data with Label Propagation[J]. ProQuest number: information to all users, 2002.

[13] Lin T Y, Goyal P, Girshick R, et al. Focal Loss for Dense Object Detection[C]//Proceedings of the IEEE international conference on computer vision. 2017: 2980-2988.

[14] Khosla P, Teterwak P, Wang C, et al. Supervised Contrastive Learning[J]. Advances in neural information processing systems, 2020, 33: 18661-18673.